

EuroSAT 十分类实验：手写三层 MLP 的实现与分析

杨晨

25210980120

[GitHub 仓库](#) | [ModelScope 权重](#)

日期：2026 年 4 月 18 日

摘要

实验对象为 EuroSAT RGB 数据集上的三层 MLP 十分类任务。实现中未使用 PyTorch、TensorFlow、JAX 等自动微分框架，仅保留 CuPy 作为数组运算后端，前向传播、交叉熵、反向传播、随机梯度下降、学习率衰减和 L2 正则均由手写代码完成。训练过程中按验证集准确率保存最优权重，正式提交模型 `final_p` 在验证集和测试集上分别达到 69.01% 和 67.58%；调整 dropout 后得到 `final_o`，其测试集准确率为 68.10%，验证集准确率为 68.77%。报告给出最终配置、实验结果，以及训练曲线、混淆矩阵、权重图和错例分析。

关键词：EuroSAT，三层 MLP，手写反向传播，CuPy，遥感图像分类

1 实验任务与实现思路

本次作业要求在 EuroSAT RGB 数据集上，从零实现一个三层神经网络分类器，并且不能依赖 PyTorch、TensorFlow、JAX 这类现成的自动微分框架。实现内容覆盖数据加载、模型定义、训练循环、测试评估和超参数搜索，报告给出训练曲线、混淆矩阵、第一层权重可视化和错例分析。

实现采用 CuPy 作为统一数组后端，模型本体由输入层、两层隐藏层和输出层组成；损失函数采用 Softmax 交叉熵，参数更新采用手写随机梯度下降。

代码仓库位于 [GitHub](#)，模型权重位于 [ModelScope](#)。其中 `final_p` 为正式提交模型，`final_o` 为扩展实验。`train.py` 中现保留的命名 preset 为 `final_a`、`final_k`、`final_l`、`final_n`、`final_p`、`final_o`。上述六组实验的摘要文件、配置文件与主要图表均已随仓库保留，可直接复核；`hw1/outputs/runs/manifest.csv` 仅作为历史实验台账使用，其中 `source_group` 区分实验来源，`tracked_in_repo` 标明该条记录是否在当前仓库中保留了可直接核验的产物。

权重仍通过 ModelScope 仓库 `youngchen/CS60003` 提供，固定下载位置和校验命令如下：

```
ModelScope: hw1/final_p/best_model.npz
             hw1/final_o/best_model.npz
Command: "$PY" -X utf8 "hw1/download_weights.py"
          "hw1/model_weights"
```

下载后路径和校验值如下：

```
hw1/final_p/best_model.npz ->
  hw1/model_weights/hw1/final_p/best_model.npz
sha256: 1d33521419a060a4670b86be58926522c5febffc
      5a64a1d63ec2d30793325d2a

hw1/final_o/best_model.npz ->
  hw1/model_weights/hw1/final_o/best_model.npz
sha256: e1295599ece6be23a20016c110dbca63359ebc82cb
      715d7db4a154b30b2457f5
```

2 数据集与预处理

EuroSAT RGB 数据集包含 10 个地表覆盖类别，每张图像的尺寸为 $64 \times 64 \times 3$ 。实验采用按类别分层划分的方式，将数据分为训练集、验证集和测试集，最终样本数分别为 18900、4050 和 4050。三个子集保持一致的类别分布。

预处理部分不使用数据增强。图像先被展平成一维向量，然后只根据训练集统计量计算均值与标准差，对训练、验证和测试样本统一做标准化。缓存在首次构建后写入本地，后续实验直接复用。

3 模型与训练设置

模型整体结构可以写成

$$\text{input} \rightarrow \text{hidden}_1 \rightarrow \text{hidden}_2 \rightarrow \text{output}.$$

其中输入维度对应展平后的图像向量，输出维度为 10。代码中支持 `relu`、`tanh` 和 `sigmoid` 三种激活函数切换，正式提交模型使用 `relu`，`dropout` 系数为 0.15。

损失函数写为

$$\mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \log p_{i, y_i} + \frac{\lambda}{2} \sum_l \|W_l\|_2^2,$$

其中前一项是交叉熵，后一项是 L2 正则。学习率采用逆时衰减策略

$$\eta_t = \frac{\eta_0}{1 + \gamma t},$$

并在参数更新前加入梯度裁剪，以抑制个别 batch 的更新幅度过大。

表 1: 正式提交模型的训练配置

项目	配置
隐藏层宽度	1280 $\rightarrow$ 768
激活函数	ReLU
Dropout 系数	0.15
批大小	256
训练轮数	44
初始学习率	0.012
学习率衰减	0.01
权重衰减	0.0002
梯度裁剪	3.0
最佳轮次	42
最佳验证集准确率	69.01 %
测试集准确率	67.58 %

表 1 给出了正式提交模型的训练配置。`final_p` 在该配置下取得验证集最高准确率 69.01%。

4 实验对比与选模

用于比较的实验包含 `final_a`、`final_k`、`final_n`、`final_l`、`final_p` 和 `final_o`。当前仓库保留了这六组实验的摘要文件与主要图表，它们共享相同的隐藏层结构与主优化参数，主要用于观察 `dropout` 与训练轮数的邻域变化；复核时既可以直接运行对应 `preset`，也可以对照各自 `summary.json` 中记录的配置。

表 2 对应当前代码中 `full` 搜索 `preset` 的候选空间，总组合数为 $4 \times 3 \times 3 \times 3 \times 3 \times 2 = 1944$ 。实际搜索阶段采用固定随机种子的候选子集抽样，从该候选空间中选取 24 组组合；抽样逻辑先保证学习率、两层隐藏宽度和权重衰减的每个候选值至少出现一次，其余名额再从打乱后的完整网格中补足。因此，搜索阶

表 2: 完整搜索 preset 的候选空间

超参数	候选取值
学习率	0.006、0.008、0.010、0.012
第一隐藏层宽度	768、1024、1280
第二隐藏层宽度	384、512、768
权重衰减	5×10^{-5} 、 10^{-4} 、 2×10^{-4}
学习率衰减	0.01、0.02、0.03
梯度裁剪	2.5、3.0、4.0
激活函数	ReLU、Tanh

表 3: 邻域补跑与最终选模结果对比

实验	隐层结构	Dropout	轮数	验证集准确率/%	测试集准确率/%
final_a	1280 → 768	0.00	36	68.49	66.69
final_k	1280 → 768	0.10	40	68.54	67.75
final_n	1280 → 768	0.12	42	68.44	66.84
final_l	1280 → 768	0.15	40	68.86	67.14
final_p	1280 → 768	0.15	44	69.01	67.58
final_o	1280 → 768	0.18	42	68.77	68.10

段主要用于定位较优区域，而不是严格的单因素消融。仓库保留了当前代码版本下重新执行的一次完整 24-trial 搜索结果，路径为 `hw1/outputs/search/20260419_045438/`，其中 `results.csv`、`results.json` 和 `best_result.json` 给出每个 trial 的超参数、验证集准确率和测试集准确率；20260409_100323 与 20260409_100536 两份历史 `search_config.json` 只作为早期搜索配置来源记录。`best_result.json` 显示，本次抽样搜索的最优 trial 使用 1280 → 768 的隐藏层宽度、初始学习率 0.012、权重衰减 0.0002、学习率衰减 0.01、梯度裁剪 3.0 和 ReLU，验证集准确率为 68.37%。为闭合这一证据链，仓库另外保留了与之对应的 `hw1/outputs/runs/trial_04/`，其中 `config.json`、`history.json`、`summary.json` 与 `confusion_matrix.json` 可直接核验该最优 trial 的配置和结果。台账文件 `manifest.csv` 在这里仅用于补充说明历史实验覆盖范围：其中 `source_group=full_search_20260419_045438` 的 `trial_04` 与本次 full search 一一对应，而 `archive_trial_*` 只是早期搜索留档别名，不能与当前 full search 的同名 trial 直接视为同一个 run。由此可见，full search 已经把较优区域定位到与 final_p 相同的主配置附近，后续邻域补跑主要是在 dropout 与训练轮数上继续细化；在当前保留的历史台账中，final_p 仍是验证集准确率最高的模型，final_o 则对应更高的测试集准确率。

表 3 展示的是在较优区域附近继续补跑后形成的邻域实验链。六组实验保持相同隐藏层结构、学习率、权重衰减和梯度裁剪，仅在 dropout 与训练轮数上做局部微调。可以看到，验证集最优出现在 final_p，测试集最优出现在 final_o，整体走势并非单调：final_l 与 final_p 说明在相同 dropout 为 0.15 时，继续训练到 44 轮可以把验证集准确率从 68.86% 提高到 69.01%；final_k、final_n、final_o 则表明围绕 0.15 做 dropout 邻域调整时，测试集结果可能上升，但验证集最优仍保持在 final_p。结合全量 manifest，final_p 仍是已留档历史 run 中验证集最高的模型。因此，正式提交按课程要求选择验证集最优的 final_p，而不是事后挑选测试集最高的结果。

5 实验结果与分析

5.1 训练曲线

在训练后段，第 34、39、42、43、44 轮的验证集准确率分别为 68.42%、68.86%、69.01%、68.00% 和 68.35%。训练集损失继续下降，而验证集准确率在第 42 轮后回落。




图 1: 正式提交模型的训练曲线

这里绘制的 **train loss** 与 **val loss** 都是不含 **L2** 正则项的数据损失，用于观察拟合趋势；正则项已经在训练更新时参与参数学习，但不单独画入曲线。这一变化说明后续训练仍在降低数据损失，但验证集收益已经停止增长。结合 **final_a** 与 **final_p** 的对比，可以看到较长训练配合适度 **dropout** 能提高验证集结果。**final_o** 仅作为补充观察：它的测试集结果略高，但验证集结果低于 **final_p**，因此没有作为按验证集选出的正式模型。

5.2 混淆矩阵与分类表现




图 2: 正式提交模型在测试集上的混淆矩阵

表 4: 正式提交模型的分类别准确率

类别	准确率/%	类别	准确率/%
AnnualCrop	71.11	Pasture	79.00
Forest	84.67	PermanentCrop	46.67
HerbaceousVegetation	57.33	Residential	65.33
Highway	39.73	River	64.80
Industrial	83.47	SeaLake	81.56

混淆矩阵显示，Forest、Industrial 和 SeaLake 的准确率均高于 80%；Highway 最低，为 39.73%；PermanentCrop 为 46.67%。

误分类次数最多的类别对列在表 5 中。最高频错误集中在植被类之间，以及细长线状地物之间。

表 5: 混淆矩阵中的高频误分类对

真实类别	预测类别	次数
PermanentCrop	HerbaceousVegetation	64
Highway	River	62
HerbaceousVegetation	PermanentCrop	50
PermanentCrop	AnnualCrop	46
River	Highway	45
Residential	Industrial	44
Forest	SeaLake	43
Highway	AnnualCrop	37

这些误分类集中在视觉结构相近的类别之间。Highway 与 River 在 64×64 的 RGB 图像中都可能呈现细长条带结构，模型在缺少卷积局部结构约束时更容易把二者混淆。PermanentCrop、HerbaceousVegetation 和 AnnualCrop 均包含大面积绿色或棕色植被区域，类别差异更多依赖田块边界、纹理密度和空间排列；展平后的全连接输入会削弱这类局部空间线索。Residential 与 Industrial 都包含规则建筑块和高反差边缘，因此也出现了 44 次 Residential 到 Industrial 的误分。




图 3: 第一层隐藏层权重可视化

5.3 第一层权重可视化

图 3 给出了第一层权重的可视化结果。图中只展示前 16 个隐藏单元；每个隐藏单元的权重先恢复为 $64 \times 64 \times 3$ ，再在该单元内部做 min-max 归一化后显示，因此该图只用于观察是否出现稳定的局部模板，不用于比较不同单元之间的绝对幅值或符号。多数权重块呈现大范围的色块交替，而不是集中在局部区域的亮斑或边缘模板；不同隐藏单元之间也没有形成稳定重复的局部纹理结构。

从图中可以看到，部分单元更接近全局颜色偏置，也有若干单元呈现较弱的横向或纵向条带。这些现象提示第一层更容易响应颜色比例、亮度分布和粗略方位等低阶统计量，但没有出现可稳定解释为“道路边缘”“河岸边界”或“作物纹理”的局部模板。

这一结果与模型结构是基本一致的。第一层权重直接作用于展平后的 $64 \times 64 \times 3$ 输入，每个隐藏单元对应整幅图像上的一个全局线性组合，而不是卷积模型中的局部共享滤波器。因此，将权重恢复成图像后，更容易看到全局颜色对比和大尺度响应分布，而不容易看到针对河流、森林这类类别的局部空间模板。换言之，一种合理解释是，当前 MLP 可能更多利用“整幅图像中哪些颜色组合同时出现”这一类粗粒度统计信号，而不是显式利用局部纹理或边缘方向。这与 Highway 与 River、PermanentCrop 与 HerbaceousVegetation 的高频混淆是相符的：这些类别的判别通常更依赖局部几何形状和纹理排列。

5.4 一组 AnnualCrop 错例



图 4: 测试集中的部分错例

图 4 中的 12 个错例全部来自 AnnualCrop。当前仓库保留的这张错例图来自顺序抽取的前 12 个误分样本，因此更适合展示一类典型误差，而不直接代表整体错误分布。AnnualCrop 在测试集上的类别准确率为 71.11%，图中预测类别包括 River、Pasture、PermanentCrop、HerbaceousVegetation 和 SeaLake。

这些样本可以分为几类。第一类是被分为 River 的样本：左上和第二行左侧图像包含深色背景上的细长亮色边界，视觉上接近河道或道路；MLP 在展平输入上难以稳定判断条带边界是否来自田块分割。第二类是被分为 Pasture 或 HerbaceousVegetation 的样本：第一行中间两幅、第二行中间两幅和第三行右侧图像以大面积绿灰或粉绿色块为主，田块纹理不强，容易接近草地或草本植被的全局颜色统计。第三类是被分为 PermanentCrop 的样本：第一行右侧、第二行右侧和第三行第二幅存在规则条带或块状排列，和永久作物的行列式纹理较接近。第三行左侧被分为 SeaLake 的样本颜色分布更均匀，缺少明显田块边界，因而被模型映射到低纹理类别。

从混淆矩阵看，AnnualCrop 被错分到 HerbaceousVegetation 33 次、PermanentCrop 32 次、River 23 次、Highway 17 次。前两类错误与农田、永久作物和草本植被在绿色/棕色色块比例上的接近有关；后两类错误通常对应图像中出现细长亮色边界、水道或道路状结构。现有结果与这样一种解释相符：当模型没有显式利用局部纹理与边界方向时，包含规则田块边界或条带结构的 AnnualCrop 样本更容易落入上述类别。

如果把视角从 AnnualCrop 扩展到整体混淆矩阵，还能看到另外两组具有代表性的高频错误。第一组是 Highway 被错分到 River 62 次、River 被错分到 Highway 45 次，这说明细长条带结构在当前输入表示下难以稳定区分。第二组是 PermanentCrop 被错分到 HerbaceousVegetation 64 次、HerbaceousVegetation 被错分到 PermanentCrop 50 次，这说明植被相关类别之间的差异更多依赖纹理密度与空间排列，而不是单纯颜色统计。Residential 被错分到 Industrial 44 次也属于类似现象：规则建筑块、道路边缘与硬质地表在低分辨率 RGB 图像上具有相近的全局统计特征。

6 结论

本次实验中，三层 MLP 的验证集准确率达到 69.01%。按验证集准确率选模时，`final_p` 高于 `final_o`；由于提交规则以验证集最优权重为准，正式结果采用 `final_p`。`final_o` 只作为相邻配置的补充观察，不作为正文分析的核心证据。

混淆矩阵表明，Highway↔River 与 PermanentCrop↔HerbaceousVegetation 是当前模型最典型的高频混淆；AnnualCrop 的顺序错例图则进一步展示了田块边界、条带结构和颜色统计接近时的误判方式。仅根据当前结果，可以稳妥得到的结论是：这类类别对在三层 MLP 上仍然较难稳定区分，而更具体的特征依赖机制还需要更有针对性的对比实验来验证。

从实验流程看，当前代码版本下的 24 组 full search 已经把较优区域稳定定位到 1280 → 768 的两层隐藏宽度附近；在此基础上继续围绕 dropout 和训练轮数做邻域补跑后，验证集最优仍落在 `final_p`。这说明本次最终配置并不是凭测试集结果事后挑选，而是在固定验证集划分、固定随机种子和一致训练流程下逐步收敛得到的。

从可复现实用性的角度看，仓库中保留了正式模型、扩展实验与当前 full search 最优 trial 的摘要文件、配置文件和主要图表，权重则通过 ModelScope 单独提供。这样既能满足课程提交对仓库体积的约束，也能让复核者直接对应 README、实验输出和报告中的关键结论。对这份作业而言，更重要的收获不只是得到一个接近 69% 验证集准确率的 MLP 结果，而是完整走通了手写前向传播、反向传播、选模与误差分析的实现闭环。