

CS60003 期中作业实验报告：分类、检测跟踪与语义分割

夏商周 25210980114 Task1
杨智超 25210980124 Task2
杨晨 25210980120 Task3

[代码仓库](#) | [模型仓库](#)

日期：2026 年 5 月 17 日

摘要

本报告记录 CS60003 期中作业三个任务的实现与实验结果。Task 1 在 102 Category Flower Dataset 上微调 ImageNet 预训练卷积网络，完成 ResNet-18 baseline、超参数对比、随机初始化消融和 SE 注意力结构对比，并额外用 ConvNeXt-Tiny 获得当前最高 test accuracy 96.08%。Task 2 在 Road Vehicle Images Dataset 上训练 YOLOv8s 检测器，最佳 epoch 的 mAP50 为 0.5150、mAP50-95 为 0.2854，并结合 ByteTrack、轨迹重连和越线判断完成 10-30 秒交通视频的多目标跟踪与计数。Task 3 在 Stanford Background Dataset 上从零手写 U-Net 与 Dice Loss，比较 Cross-Entropy、Dice 与 CE+Dice 三组损失，并在不使用预训练和现成分割模型的约束下继续优化到 validation mIoU 70.1053%。

关键词：Flowers102，YOLOv8，ByteTrack，ResNet 微调，U-Net，Dice Loss，SwanLab

1 实验总览与提交资源

本次作业包含三个任务。代码统一提交至公开 [GitHub 仓库](#)，训练权重与关键实验产物统一发布到 ModelScope [模型仓库](#)，按 `hw2/task1/`、`hw2/task2/` 与 `hw2/task3/` 子目录组织。

表 1: 当前报告覆盖范围与交付物

任务	当前状态	主要交付物
Task 1	已完成 Flowers102 分类实验、SwanLab 记录和 ModelScope 上传	仓库 : <code>hw2/task1/.../best.pt</code>
Task 2	已完成车辆检测训练、视频多目标跟踪、遮挡分析和越线计数	仓库 : <code>hw2/task2/.../best.pt</code>
Task 3	已完成 Stanford Background 分割实验、SwanLab 记录和 ModelScope 上传	仓库 : <code>hw2/task3/.../best.pt</code>

报告中的训练曲线来自 SwanLab 实验记录或同一训练历史导出的图片，已随报告图片目录保存，正文不公开私有实验页面。为保证材料可复现，Task 2 除检测权重外还保留 `metrics.json`、`history.csv`、跟踪配置和 30/60 fps 两组计数摘要。

2 Task 1: ImageNet 预训练卷积网络的 Flowers102 微调

2.1 任务要求与实现概述

Task 1 要求在 102 Category Flower Dataset 上修改 CNN 输出层作为 baseline，使用 ImageNet 预训练参数初始化，采用较小学习率微调 backbone、较大学习率训练新分类头，并观察训练步数、学习率等超参数的影响。同时，还需要比较随机初始化与预训练初始化，并在 baseline 基础上加入注意力模块或使用轻量 Transformer 进行对比。

实现位于 `hw2/task1/`。数据读取严格使用官方 `setid.mat`：训练集、验证集和测试集分别为 1020、1020 和 6149 张。模型构建使用 `torchvision` 中的 ResNet-18/34/50、EfficientNet-B0 与 ConvNeXt-Tiny；其中 baseline 与作业主线围绕 ResNet-18/34 展开，ConvNeXt-Tiny 只作为额外提升模型报告。优化器支持 SGD 与 AdamW，训练过程中按验证集 accuracy 保存最佳 checkpoint。

2.2 模型与训练设置

Baseline 使用 ImageNet 预训练 ResNet-18，将原分类层替换为 102 类线性层。参数组分为 backbone 和 classifier 两部分，baseline 的 backbone learning rate 为 1×10^{-4} ，classifier learning rate 为 1×10^{-3} 。随机初始化消融只把 pretrained 置为 false，其余训练预算保持可比。注意力模型采用手写 SE block 插入 ResNet BasicBlock 的第二个 batch normalization 之后、残差相加之前。

表 2: Task 1 数据与 baseline 训练配置

项目	配置
数据集	Oxford 102 Category Flower Dataset, 102 类
官方划分	train 1020 / val 1020 / test 6149
输入尺寸	224×224 ；最终高分实验使用相同尺寸
Baseline	ImageNet 预训练 ResNet-18，替换 102 类输出层
优化器	SGD, momentum 0.9, cosine scheduler
学习率	backbone 1×10^{-4} , classifier 1×10^{-3}
训练轮数	baseline 40 epochs；优化实验最高 71 epochs
Batch size	baseline 64；ConvNeXt-Tiny 最终实验 32
正则与损失	baseline Cross-Entropy + weight decay 10^{-4} ；最终实验使用 AdamW、weight decay 0.05 和 label smoothing 0.05
增强策略	baseline 使用标准随机裁剪/翻转；最终实验加入 RandAugment、RandomErasing 和 horizontal-flip TTA
评价指标	validation accuracy 选模，test accuracy 报告最终泛化结果

2.3 Baseline、消融与超参数对比


表 3 汇总了报告必要实验。Baseline test accuracy 为 68.19%。随机初始化 ResNet-18 在相同训练预算下只有 15.71%，说明 ImageNet 预训练对小样本细粒度花卉分类至关重要。低学习率和短训练轮数均明显欠拟合；加入 label smoothing 后，ResNet-18 test accuracy 提升到 76.89%。SE-ResNet-18 虽然满足注意力结构要求，但当前设置下没有超过 baseline；这只能说明当前 SE 插入位置和训练策略未带来收益，不能推出注意力机制总体无效。ResNet-34 强增强作为 ResNet 系列优化代表达到 81.72%。最终额外优化模型 ConvNeXt-Tiny 达到 96.08%，用于最终模型提交。图 1 展示了 baseline 与最终模型的训练曲线差异，ConvNeXt-Tiny 的验证 accuracy 更快进入高位且后期波动更小。

2.4 Task 1 小结


Task 1 的合规主线由 ResNet-18 baseline、学习率/epoch 超参数对比、随机初始化消融和 SE 注意力对比构成。最终提交模型选择 ConvNeXt-Tiny，是在完成主线要求后额外加入的强 ImageNet 预训练 backbone。ConvNeXt-Tiny 的优势主要来自更强的 ImageNet 表征、现代卷积结构、AdamW 正则化和更充分的数据增强；注意力机制实验仍以 SE-ResNet-18 为依据。

表 3: Task 1 关键实验结果 (粗体为最佳, 下划线为次优)

实验	作用	Best val acc	Test acc
Baseline ResNet-18	预训练 baseline	0.7186	0.6819
低学习率 ResNet-18	学习率消融	0.4873	0.4506
较短训练 ResNet-18	训练步数消融	0.5725	0.5307
随机初始化 ResNet-18	预训练消融	0.1794	0.1571
SE-ResNet-18	注意力机制对比	0.4500	0.4245
ResNet-18 label smoothing	超参数优化	0.7745	0.7689
ResNet-34 增强	ResNet 系列优化	<u>0.8284</u>	<u>0.8172</u>
ConvNeXt-Tiny 优化	最终额外提升模型	0.9784	0.9608



(a) Baseline ResNet-18



(b) ConvNeXt-Tiny 最终优化

图 1: Task 1 SwanLab 曲线。横轴为 Epoch, 纵轴为 Loss 与 Accuracy。

3 Task 2: Road Vehicle 目标检测与多目标跟踪

3.1 任务要求与实现概述

Task 2 围绕交通场景中的车辆检测与多目标跟踪展开。作业要求先在 Road Vehicle Images Dataset 上微调 YOLOv8 或同类现代单阶段检测器, 得到自己的检测权重; 再选取一段 10–30 秒的测试视频, 逐帧输出 bounding box、类别和 tracking ID, 并进一步分析遮挡场景下的 ID 稳定性, 最后根据虚拟线完成越线计数。

实现位于 hw2/task2/。整体流程先训练 YOLOv8s 检测器, 得到逐帧类别、置信度和边界框; 随后将检测结果输入 ByteTrack 维护轨迹, 并在 raw track id 之上增加一层 display id, 用于视频可视化和越线计数。检测阶段只解决单帧定位问题, 跟踪阶段再利用目标中心点的时间连续性判断 ID 延续与越线事件。由于测试视频中存在小二轮车、密集交汇和短时遮挡, 最终计数还加入了轨迹重连、短时丢失目标预测和重复越线去重。

3.2 检测模型与训练设置

检测模型采用 YOLOv8s。该模型仍属于单阶段检测框架,推理速度适合视频流处理,同时比 YOLOv8n 具备更强的特征表达能力,对远处车辆和二轮车等小目标更稳。数据集使用 Road Vehicle Images Dataset 的 YOLO 标注格式,共 21 个类别,训练集和验证集分别为 2704 与 300 张图像。

表 4: Task 2 检测训练配置

项目	配置
数据集	Road Vehicle Images Dataset, YOLO 标注格式, 21 类
划分	train 2704 / valid 300
检测模型	YOLOv8s, COCO 预训练权重初始化后微调检测头与 backbone
输入尺寸	640 × 640
训练轮数	50 epochs, 保存验证集 mAP 最优 checkpoint
Batch size	16
优化器	AdamW, 初始学习率 0.001, 最终学习率比例 0.01, warmup 3 epochs
混合精度	AMP 开启
跟踪阈值	推理置信度 0.1, ByteTrack track_buffer=120

3.3 检测训练结果

表 5 给出检测模型的主要指标。最佳 checkpoint 出现在 epoch 38, mAP50 为 0.5150, mAP50-95 为 0.2854。该结果能够支撑后续视频跟踪,但也说明检测框质量仍有提升空间:在较宽松 IoU 阈值下模型可以较稳定地发现车辆,而在更严格阈值下,小目标、遮挡目标和边界不清晰目标仍容易产生定位误差。

表 5: Task 2 YOLOv8s 检测结果

模型	Best epoch	mAP50	mAP50-95
YOLOv8s baseline	38	0.5150	0.2854




图 2: Task 2 YOLOv8s 训练曲线。左图为 box loss, 右图为 mAP50 与 mAP50-95。

图 2 中训练 box loss 持续下降,说明边界框回归在训练过程中稳定收敛。验证 box loss 的波动更明显,主要来自道路场景中尺度差异很大的车辆、远处小目标以及局部遮挡目标。mAP50 在训练中后段逐步提升到约 0.5, mAP50-95 的增幅相对有限,说明模型已经具备可用的召回和粗定位能力,但高精度框定位仍是后续跟踪的主要误差来源。基于这一点,视频推理阶段没有使用过高置信度阈值,而是保留部分低置信度检测交给 ByteTrack 进行时序筛选。

3.4 视频跟踪与越线计数

视频推理阶段分别处理 30 fps 与 60 fps 两个版本。每一帧先由训练好的 YOLOv8s 产生检测框，再由 ByteTrack 根据框位置、置信度和运动预测生成 raw track id。输出视频中，每个目标均显示 bounding box、类别、display id 与置信度，例如 `motorbike #11 0.52`。display id 不直接等同于 ByteTrack 的 raw id，而是在短时遮挡或漏检后尝试延续同一目标身份，避免视频中频繁出现 ID 断裂。

越线计数使用竖直虚拟线。对每个 display id，记录检测框中心点 $c_x = (x_1 + x_2)/2$ 在相邻帧中位于 counting line 的哪一侧；当中心点从一侧移动到另一侧，且该 display id 尚未被计入时，触发一次 crossing event。对于已经接近 counting line、随后短时消失的轨迹，代码会根据最近速度预测其是否可能在丢失期间穿线，并作为 missing crossing 补计。这个逻辑利用了 tracking ID 的连续性，比单帧检测框计数更适合拥挤路口视频。

表 6: Task 2 视频跟踪与越线计数结果

视频	分辨率 / fps	帧数	计数线	最终计数	缺失预测补计
test_video.mp4	1280 × 720 / 30	915	$x = 640$	19	5
IMG_8813.MOV	1920 × 1080 / 60	1828	$x = 960$	25	7

两个视频的计数线都放在画面水平中点，因此不同分辨率下分别对应 $x = 640$ 与 $x = 960$ 。加入 display id 重连和 missing crossing 预测后，30 fps 版本得到 19 次越线，60 fps 版本得到 25 次越线。60 fps 视频具有更高帧率和更大空间分辨率，能够保留更多短时运动细节；同时，密集目标带来的重复检测和 ID 断裂也更明显，因此补计数量高于 30 fps 版本。

3.5 遮挡与 ID 跳变分析


遮挡和密集交汇是多目标跟踪中最容易破坏 ID 连续性的情况。图 3 选取 60 fps 视频中 15.85–15.90 秒的连续四帧作为失败案例进行分析。该片段右侧两辆二轮车几乎并行通过，目标尺度相近、类别相同，局部区域还存在行人和路边背景干扰。可视化结果显示，两辆不同二轮车在这几帧中都被标为 `motorbike #11`，说明该局部片段中没有成功维持稳定 ID，而是发生了 ID merge。报告保留这个失败片段，是为了说明最终系统在密集遮挡场景中的边界条件，而不是把它作为理想跟踪结果展示。

这一问题主要来自轨迹关联，而不是单帧检测。ByteTrack 依赖检测框位置、运动预测和置信度进行匹配，本身不显式使用外观 ReID 特征。当两个同类小目标短时间内距离很近，且检测框大小和运动方向相似时，卡尔曼预测和 IoU 匹配很难可靠地区分身份。后处理阶段为了减少 ID 断裂，又会根据类别族、预测位置和框尺寸把新 raw id 接回旧 display id；在该片段中，重连条件对相似二轮车过于宽松，使两个同时存在的目标共享了同一个 display id。

针对这类失败案例，后处理逻辑已经加入更保守的同帧保护：如果旧 raw id 仍在当前帧出现，就不再把另一个 raw id 接到同一个 display id 上。该规则用于降低同一帧内的 display id 复用风险，但图 3 仍表明，仅依赖几何位置、框尺寸和短时运动信息，不能从根本上解决遮挡后的身份恢复问题。若要进一步提升 ID 稳定性，需要引入外观 ReID 特征、相机运动补偿或更强的多目标跟踪器。

3.6 Task 2 小结

Task 2 最终得到一套基于 Road Vehicle 数据集微调的 YOLOv8s 检测权重，验证集 mAP50 为 0.5150。结合 ByteTrack 和 display id 后处理后，系统能够在测试视频中输出类别、检测框、跟踪 ID 和越线总数，30 fps 与 60 fps 两个版本分别统计到 19 与 25 次越线。主要不足集中在小目标、遮挡和相似目标密集交汇场景；frame 950–953 的例子表明，几何和运动信息足以改善部分漏计数，但在没有外观 ReID 的情况下仍可能发生 ID merge。



Cropped occlusion interval: duplicated display ID #11 on similar two-wheelers.

图 3: Task 2 遮挡片段裁剪图。frame 950–953 中两辆相似二轮车被错误映射到同一个 display id #11。

4 Task 3: 从零搭建 U-Net 与 Dice Loss 的语义分割

4.1 任务要求与数据口径

Task 3 要求不使用任何预训练权重，从深度学习框架基础 API 手写 U-Net，包含完整下采样编码器、上采样解码器与 skip connection，并手写 Dice Loss。数据集为 Stanford Background Dataset，需要分别使用 Cross-Entropy、Dice Loss 和 CE+Dice 训练并比较验证集 mIoU。

实现位于 `hw2/task3/`。数据集中共有 715 张图像与对应 `.regions.txt` 标签，固定 `seed=42` 划分为 train 572 / val 143。标签包含 8 个语义类：sky、tree、road、grass、water、building、mountain、foreground object；原始 unknown 标签 -1 映射为 ignore index 255，不参与 loss、pixel accuracy、mIoU 和 per-class IoU。

4.2 U-Net 结构与 Dice Loss

基础网络由四级 encoder、bottleneck、四级 decoder 和 1×1 输出卷积组成。每级编码块为两层 Conv-BatchNorm-ReLU，downsampling 使用 max pooling，upsampling 使用转置卷积或双线性上采样，随后与对应 encoder 特征拼接。最终优化中的 Attention U-Net 在 skip connection 前加入 additive attention gate，用 decoder gate feature 过滤 encoder skip feature。

Dice Loss 使用 softmax 概率和 one-hot 标签计算，并先用 ignore mask 去除 unknown 像素。对第 c 类，其 soft Dice 写为

$$D_c = \frac{2 \sum_i p_{ic} y_{ic} + \epsilon}{\sum_i p_{ic} + \sum_i y_{ic} + \epsilon},$$

整体 Dice Loss 为 $1 - \frac{1}{C} \sum_c D_c$ 。组合损失为

$$\mathcal{L} = \mathcal{L}_{CE} + \mathcal{L}_{Dice}.$$

验证 mIoU 对每个非 ignore 类分别计算 $\text{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}$ ，再对 8 个语义类取平均；unknown 像素不进入混淆矩阵和 mIoU 统计。

表 7: Task 3 数据与训练配置

项目	配置
数据集	Stanford Background Dataset
样本划分	train 572 / val 143, 固定 seed=42
类别数	8 类; unknown 像素 ignore
基础输入尺寸	240 × 320; 优化实验使用 256 × 320
基础模型	从零手写 U-Net, base channels 32
最终模型	从零手写 Attention U-Net, base channels 64
选模指标	validation mIoU
最终评估增强	horizontal-flip TTA + multi-scale TTA [0.6, 0.8, 1.0, 1.2, 1.4]
优化器与学习率	AdamW + cosine scheduler; 基础实验 lr 3×10^{-4} , 最终实验 lr 2×10^{-4}
Batch size 与训练轮数	基础实验 batch size 8 / 80 epochs; 最终实验 batch size 4 / 130 epochs
数据增强	horizontal flip、color jitter、random scale crop; 所有模型均从零训练

4.3 三组损失函数对比

表 8 为作业要求的三组基础实验。CE、Dice 和 CE+Dice 的 mIoU 非常接近，其中 CE+Dice 在单次实验中以 0.648970 略优。结合 per-class IoU，Dice-only 在 mountain 类上更好，但整体 pixel accuracy 略低；CE+Dice 在 sky、tree、grass、water、building 等主要类别上更均衡，因此作为后续优化基础。

表 8: Task 3 基础 loss 对比

实验	损失函数	Best epoch	Val mIoU	Val pixel acc
task3_unet_ce	Cross-Entropy	69	0.648151	0.833211
task3_unet_dice	手写 Dice Loss	63	0.648211	0.829996
task3_unet_ce_dice	CE + Dice	52	0.648970	0.834739





图 4: Task 3 CE+Dice 基础实验曲线。训练过程中记录 loss、mIoU 和 pixel accuracy。

4.4 进一步优化与最终模型


在不违反作业约束的前提下，后续优化只修改从零训练的 U-Net 家族结构、输入尺寸、数据增强和评估增强。第一轮优化将 base channels 扩大到 64、输入调整到 256 × 320，并加入 dropout 和 horizontal-flip TTA，使 mIoU 从 0.648970 提升到 0.665089。进一步加入 Attention Gate 后，plain Attention U-Net 达到 0.667801；再加入 random scale crop 和多 seed 尝试后，最终选择 seed=7 的 Attention U-Net checkpoint，并用多尺度 TTA 得到 0.701053。需要注意，Stanford Background 当前实验只使用固定 train/val 划分，因此最终结果是 validation mIoU，而不是独立测试集指标；多尺度 TTA 也在该验证协议下选择。

表 9: Task 3 关键优化链路

实验	关键变化	Val mIoU	Val pixel acc
task3_unet_ce_dice	基础 U-Net + CE+Dice	0.648970	0.834739
task3_unet_ce_dice_b64_tta	base=64, 256×320 , dropout, flip TTA	0.665089	0.842011
task3_attention_unet_b64_tta	加入 Attention Gate	0.667801	0.843214
task3_attention_unet_b64_aug_seed7_tta	random scale crop, seed=7	0.695953	0.859910
最终多尺度复评	flip + multi-scale TTA	0.701053	0.864931



(a) Attention U-Net 结构优化



(b) 最终模型曲线

图 5: Task 3 代表性 SwanLab 曲线。

图 6 中, sky、road、building 等大面积区域通常较稳定, 边界和小目标仍更容易出现误分割; mountain 类在最终 per-class IoU 中仍偏低, 主要与样本占比小、外观和 tree/building/foreground object 混淆有关。

表 10: Task 3 最终模型 per-class IoU

类别	IoU	类别	IoU
sky	0.904431	water	0.738596
tree	0.711124	building	0.759705
road	0.839109	mountain	0.249698
grass	0.764386	foreground object	0.641374




图 6: 最终 Attention U-Net 在验证集上的分割样例与类别颜色图例。

4.5 mIoU 0.75 目标优化尝试与约束分析

围绕 mIoU 0.75 目标, 进一步尝试了 U-Net++, scSE、ASPP bridge、deep supervision、Lovasz-Softmax、更高分辨率和更大 batch。所有模型仍从零训练, 没有使用 SAM、DeepLab、SegFormer、torchvision segmentation models、外部数据或预训练权重。最好尝试为 task3_unetpp_b64_384_lovasz_ds_tta, 多尺度复评约为 0.6953, 低于最终推荐模型。因此, 在当前 hw2.md 约束下, 继续堆高分辨率或更复杂从零结构并没有带来接近 0.75 的收益; 若要显著突破, 可能需要预训练 backbone、外部数据、现成强分割模型或 ensemble, 但这些超出当前作业约束, 因此未采用。

5 结论

Task 1 已完整覆盖 baseline、超参数分析、预训练消融和注意力结构对比; 最终额外优化模型 ConvNeXt-Tiny 在测试集上达到 96.08%。Task 2 已按 hw2.md 要求完成 Road Vehicle 数据集上的 YOLOv8s 专属检测模型训练、交通视频逐帧检测与多目标跟踪、遮挡片段 ID 跳变分析和基于虚拟线的越线计数; 检测模型最佳 mAP50 为 0.5150, 两个视频版本的最终计数分别为 19 与 25。Task 3 已完整覆盖从零手写 U-Net、手写 Dice Loss 和三组 loss 对比; 最终在严格不使用预训练和现成分割模型的约束下达到 validation mIoU 70.1053%。