

CS60003 期末作业实验报告：3DGS/AIGC 资产融合与 ACT 跨环境泛化

夏商周 25210980114 Task1 多源资产生成、3DGS/AIGC 模型训练与资产导出
杨智超 25210980124 Task1 统一表示、坐标对齐、融合渲染、相机与视觉优化、报告整合
杨晨 25210980120 Task2 数据处理、ACT 训练、跨环境评估与统计分析

[代码仓库](#) | [模型仓库](#)

日期：2026 年 6 月 17 日

摘要

本报告对应 CS60003 期末作业。Task 1 完成了真实物体 3DGS 重建、文本到 3D 生成、单图到 3D 生成、Mip-NeRF 360 背景重建，以及统一 Gaussian splat 表达下的多源资产融合渲染。最终视频直接加载 A/background 的 3DGS splat 与 B/C 的纹理 Mesh surface splat，在同一 gsplat renderer 和前景聚焦相机轨迹下输出 1920×1080、24 fps、6 秒漫游视频。Task 2 完成基于 LeRobot ACT 的 CALVIN 跨环境泛化实验：分别训练环境 A 单环境策略与环境 A/B/C 多环境联合策略，并在未见过的环境 D 上做 zero-shot 离线评估。主要结果使用不依赖 D 环境选模的 final.pt，多环境模型将 Action LI 从 0.1886211640 降至 0.1549013643，相对提升 17.88%。配对统计显示，act_splitABC 在 78.86% 的 episode、91.26% 的 task 和 7/7 个动作维度上优于 act_splitA。

关键词：3D Gaussian Splatting, AIGC, LeRobot, ACT, CALVIN, Zero-shot 泛化

1 实验总览与提交资源

本次期末作业包含两个任务。代码统一维护在公开 [GitHub 仓库](#)，模型权重统一托管在 ModelScope [youngchen/CS60003](#) 项目下。Task 1 的 3DGS 与生成模型权重位于 [hw3/task1/real_high_quality/](#)，代码与融合渲染脚本位于 [hw3/task1/](#)；Task 2 的正式权重、训练摘要与评估表位于 [hw3/task2/](#)。

表 1: HW3 报告覆盖范围与交付资源

任务	当前报告状态	主要交付物
Task 1	已完成三类资产、背景 3DGS、统一表达融合视频、质量评估与局限分析	ModelScope Task1 权重 ； GitHub hw3/task1/
Task 2	已完成数据、方法、训练、评估、统计分析、曲线和权重托管	GitHub hw3/task2/results/ ； ModelScope Task2 权重

两个任务的可复核证据均随公共仓库发布。Task 1 的训练设置、权重清单与严格产物检查说明位于 [hw3/task1/README.md](#) 和 [hw3/task1/MODELSCOPE_WEIGHTS.md](#)，六个最终模型文件位于 ModelScope 的 [hw3/task1/real_high_quality/](#)；Task 2 的提交图表位于 [hw3/task2/results/figures/](#)，对应曲线数据位于 [hw3/task2/results/curves/](#)。为避免 zero-shot 结论被 D 环境选模污染，正文主结果使用最终 checkpoint final.pt；best.pt 仅作为模型潜力参考。

2 Task 1: 基于 3DGS 与 AIGC 的多源资产生成与真实场景融合

2.1 任务目标与技术路线

本节围绕一个统一的场景融合目标展开：将真实多视角重建、文本到 3D 生成和单图到 3D 生成得到的三类资产，放入同一个真实重建背景中并输出多视角漫游视频。最终路线不采用 2D 贴片或后期图像合

成，而是把四类资产全部转为可由 `gsplat` 统一渲染的 Gaussian splat 表达：物体 A 与背景直接使用 3DGS 导出的 `splat.ply`；物体 B/C 由 `threestudio` 导出带纹理 OBJ，再对 mesh surface 采样，生成带颜色、法向和各向异性尺度的 surface splats。最终渲染脚本为 `render_fused_splats.py`，它在同一相机路径、同一深度排序和同一 rasterizer 中渲染 A/B/C 与背景，因此可以避免“把 2D 图片贴到视频上”的不一致问题。

整体流程如下：

1. 物体 A：手机拍摄真实物体环绕视频，使用 COLMAP 恢复位姿，并用 Nerfstudio `splatfacto` 训练真实物体 3DGS。
2. 物体 B：编写文本 prompt，在 `threestudio` 中使用 SDS Loss 与 Stable Diffusion 先验生成虚拟 3D 物体，并导出 OBJ/MTL/texture。
3. 物体 C：手机拍摄单张真实物体图片，先去背景得到前景图，再用 Zero123 生成多视角一致的 3D mesh。
4. 背景：选择 Mip-NeRF 360 counter 场景，使用 Nerfstudio `splatfacto` 重建为背景 3DGS。我们曾测试 garden 桌面视角，但桌面 3DGS 局部空洞明显；程序化补片会产生“假图层”观感，因此最终采用遮挡更可控的 counter。
5. 融合：统一坐标系、尺度、地面高度和相机焦点；对 A 做空间主体过滤、PCA 竖直化和高亮压制；对 B/C 采样为 surface splats；最终输出前景聚焦的 1080p 漫游视频。

2.2 数据集与资产设置

表 2 汇总了 Task 1 使用的数据来源、训练配置和主要产物。物体 A/C 来自手机实拍，物体 B 来自文本 prompt，背景来自开源 Mip-NeRF 360 数据集。所有训练与渲染脚本均由 `train.py` 生成，最终 run 目录为 `task1_real_quality_v2`。

表 2: Task 1 数据来源、方法与融合产物

对象	输入来源	方法与设置	融合阶段使用的产物
物体 A	手机真实物体环绕视频，抽取约 83 帧	COLMAP 位姿 + Nerfstudio <code>splatfacto</code> ，约 30k steps；导出 3DGS splat	A 的 <code>splat.ply</code> ；过滤、竖直化后保留 42,924 个 splat
物体 B	文本 prompt：水晶蘑菇类虚拟物体	threestudio + SDS Loss，约 15k steps；导出 OBJ/MTL/texture	B 的带纹理 OBJ；融合时采样 260,000 个 surface splat
物体 C	手机单张真实物体图像，去背景后输入	Zero123XL，约 1200 steps；导出 OBJ/MTL/texture	C 的带纹理 OBJ；融合时采样 120,000 个 surface splat
背景	Mip-NeRF 360 counter 场景	Nerfstudio <code>splatfacto</code> ，约 30k steps；导出背景 3DGS	背景 <code>splat.ply</code> ；局部清理后保留 494,805 个 splat

表 3: Task 1 训练设置与质量状态

对象	训练设置 / 指标	现象与限制
物体 A	约 30k steps；权重路径 <code>nerfstudio/object_a/</code>	几何来自真实多视角，文字和材质较可信；反光和曝光导致少量白色 splat 噪声
物体 B	约 15k steps；权重路径 <code>object_b_threestudio/</code>	语义满足“蘑菇”，但颜色偏蓝绿，和 prompt 中的 violet crystal 有偏差
物体 C	约 1200 steps；权重路径 <code>object_c_zero123/</code>	正面外观较稳定，背面和侧面由生成先验补全，部分角度不如 A 稳定
背景	约 30k steps；PSNR 28.48 / SSIM 0.8840 / LPIPS 0.0744	counter 遮挡较多，但比 garden 桌面空洞更适合最终展示

2.3 方法原理简述

3D Gaussian Splatting. 3DGS 用一组三维高斯椭球表示场景，每个高斯包含中心、协方差/尺度、旋转、不透明度和颜色。渲染时将三维高斯投影到图像平面并按深度 alpha compositing。相比显式 mesh，3DGS 对真实照片重建更友好，能保留复杂材质和视角相关细节；相比 NeRF，3DGS 渲染速度更快，适合生成漫游视频。本实验中物体 A 和背景均使用这一形式作为原生表示。

SDS 文本到 3D. 物体 B 使用 threestudio 的 SDS 路线：随机相机下渲染当前 3D 表示，把渲染图送入预训练 2D 扩散模型，根据扩散去噪梯度优化 3D 参数。SDS 的优势是只需文本即可生成想象物体；限制是几何主要来自 2D 先验，容易出现多面不一致和 prompt 偏差。本实验中的 B 最终更接近绿色/蓝绿色蘑菇，而非完全符合 prompt 中的 violet crystal。

Zero123 单图到 3D. 物体 C 使用 Zero123XL。输入是一张去背景后的正面图，模型根据相机变换条件生成新视角监督，再优化出 3D mesh。该路线能保留输入图正面外观，但背面和侧面没有真实观测，几何闭合和纹理连续性弱于多视角重建。

2.4 统一表达与融合渲染

对于 AIGC mesh 与 3DGS 背景的表达差异，我们采用代码级统一，而不是在 Blender 中分层合成。对 B/C，首先从 OBJ 表面按三角形面积采样点，读取纹理颜色并估计 surface normal；然后为每个采样点生成一个法向对齐的各向异性 Gaussian：切向尺度控制表面覆盖，法向尺度较小以避免厚片感。这样 B/C 可以和 A/background 一起传入同一个 gsplat rasterization 调用。

融合前还做了三类几何整理。第一，所有资产按 robust percentile 估计高度，并归一化到统一尺度，再放置到背景相机焦点附近的台面区域。第二，为避免背景原有物体严重遮挡 A/B/C，在插入区域执行椭圆形 support volume clearing，只删除背景局部体积中的高斯点，保留表面附近点以减少“空洞”。第三，针对最终版本中物体 A 的两个问题，增加了专门的渲染前处理：若颜色锚点过滤失败，则使用空间主体过滤去除离群 splat；用 PCA 主轴估计 A 的倾斜角并旋正到世界 z 轴；对高亮白点做 luminance/channel damping，降低白色碎片和局部曝光感。

最终相机不再沿背景原始厨房轨迹大范围扫过，而是使用前景聚焦 orbit：半径 2.20，高度 1.02，目标高度 0.34，最终 focal scale 1.476，角度范围 38° 到 72°。原始任务只规定生成多视角漫游渲染视频，并未限定必须复用背景数据集的原始相机轨迹；因此这里把 A/B/C 三个插入资产作为镜头中心，同时保留足够背景上下文来说明它们确实位于同一个重建场景中。

2.5 实验结果与可视化

最终视频相对于 Task 1 目录位于 [fused_scene.mp4](#)。视频参数为 1920×1080、24 fps、144 帧、6 秒；严格验证脚本 `evaluate.py --strict-real-outputs` 返回 PASS。图 1 展示了 7 个时间点的接触表，图 2 展示中间帧细节。



图 1: Task 1 最终融合视频关键帧接触表。相机始终围绕 A/B/C 前景资产观察，而不是沿背景厨房大范围漂移。

2.6 三种资产生成方式对比与现象分析

表 5 从几何准确度、纹理细节和资产生成耗时三个维度比较多视角重建、文本生成和单图生成。这里的耗时指资产生成或重建阶段，而不是最终融合视频渲染时间；最终 144 帧 1080p 视频渲染对三类资产共享同一 gsplat pipeline，manifest 记录为 58.98 s，更适合作为最终 renderer 性能信息。由于 Nerfstudio、



图 2: Task 1 最终视频中间帧。A 为真实重建 splat, B/C 为 mesh surface splats, 背景为 Mip-NeRF 360 counter 的 3DGS。

表 4: Task 1 最终融合渲染 manifest 摘要

项目	数值 / 设置
Renderer	gsplat fused splat renderer, pipeline_mode=fused_splats
输出规格	1920×1080, 24 fps, 144 frames, 6.0 s
相机	前景 orbit; radius 2.20, height 1.02, target z 0.34, focal scale 1.476
背景 splats	494,805
物体 A splats	42,924; 空间主体过滤 + 16.96° PCA 旋正 + 高亮通道上限 0.84
物体 B splats	260,000, 从 OBJ 纹理表面采样
物体 C splats	120,000, 从 OBJ 纹理表面采样
验证	evaluate.py --strict-real-outputs: PASS; 单元测试 30/30 通过

threestudio 和 Zero123 的日志格式并不完全一致, 表中同时保留训练 steps 和日志/文件时间口径。整体来看, 真实多视角重建最适合保留已观测物体的真实材质, 但依赖拍摄质量和 COLMAP 注册; 文本到 3D 最自由, 但和 prompt 的颜色/细节一致性最弱; 单图到 3D 生成开销最低, 但未观测侧面的幻觉最明显。

表 5: Task 1 三种 3D 资产生成方式对比

维度	A: 真实多视角 3DGS	B: 文本到 3D / SDS	C: 单图到 3D / Zero123
输入信息	真实视频多帧, 具有多视角几何约束	单段 prompt, 无真实几何观测	单张真实图, 正面信息强, 背面无观测
几何准确度	已观测表面最可信; 少纹理和反光区域会产生 splat 噪声	形体语义可用, 但由 2D 先验驱动, 局部几何可能漂移	正面较稳定, 侧/背面依赖生成先验, 闭合性有限
纹理细节	来自真实拍摄, 局部文字和材质可保留; 受曝光和重建质量影响	风格化明显; 本实验颜色偏蓝绿, 与 violet prompt 有偏差	保留输入图主视觉, 但多视角纹理连续性弱于 A
资产生成耗时	COLMAP/前处理日志约 20 min; 30k 3DGS steps 的训练日志文件时间约 8.3 min	15k SDS steps; 从 checkpoint 到 OBJ/texture 导出的文件时间约 33 min, 单步开销较高	1200 Zero123 steps; checkpoint/log 文件时间约 12 min, 相对最轻量
适合用途	真实物体复现、需要报告中体现重建能力的资产	创造不存在的虚拟物体、补充语义多样性	从一张实拍图快速扩展 3D 展示资产

最终版本的主要视觉问题来自真实数据和表示差异，而不是后期合成。A 的原始 3DGS 表面存在少量白色碎片，这是拍摄曝光、反光材质和 splat 训练共同导致的。我们通过提高 A 的 opacity quantile、取消额外不透明放大、空间主体过滤、PCA 垂直化和高亮通道压制将问题控制在可接受范围内，但如果完全消除白色碎片，需要重新拍摄更均匀的 A 多视角素材或重新训练 A。B/C 的 surface splats 让 mesh 可以进入统一 renderer，但仍不如原生 3DGS 那样具有视角相关外观。背景方面，counter 的台面区域遮挡较多；我们选择前景聚焦相机和局部背景清除来保证三个插入物体可见，这是展示目标和物理遮挡之间的折中。

3 Task 2: 基于 LeRobot 的 ACT 策略跨环境泛化挑战

3.1 任务要求与直观解释

Task 2 主要看一个问题：视觉-动作策略换到没见过的 CALVIN 环境后，动作还稳不稳。每个 episode 可以理解成一段机器人操作演示，输入是主视角图像、腕部视角图像和机器人状态，输出是下一步或未来一小段动作。这里训练两个策略：一个只用环境 A 的演示，另一个混合使用环境 A/B/C 的演示；最后都放到没有参与训练的环境 D 上测试。若 A/B/C 模型在 D 上的动作误差更低，说明它不只是记住了环境 A 的背景和摆放方式，而是学到了一些更接近任务本身的操作规律。

具体做法分三步：先只用环境 A 训练一版 ACT；再在同样网络结构和核心超参数下，用环境 A/B/C 训练第二版；最后固定到环境 D 做 zero-shot 离线评估。数据沿用课程提供的 CALVIN LeRobot 划分，split 映射为 splitA=A、splitB=B、splitC=C、splitD=D。

3.2 数据集与实验划分

数据集采用课程提供的 xiaoma26/calvin-lerobot 划分。每个 episode 以 LeRobot/parquet 格式存储，核心字段包括主视角 image、腕部视角 wrist_image、机器人状态 state、动作 actions、时间戳和任务索引。表 6 给出训练和评估使用的数据规模。

表 6: Task 2 CALVIN LeRobot 数据划分

Split	对应环境	Episode 数	Frame 数	用途
splitA	A	6089	366693	单环境训练；联合训练
splitB	B	6115	367096	联合训练
splitC	C	5666	337954	联合训练
splitD	D	5124	308918	zero-shot 评估

3.3 方法：ACT 与动作分块机制

ACT 的核心思想是一次预测未来一段动作，而不是每一帧只预测一个动作。本实验设置 chunk size 为 16，即模型根据当前双视角图像和机器人状态，一次输出未来 16 步动作片段。这样做有两个好处：一是动作序列更平滑，短时视觉噪声不会立刻导致动作大幅跳变；二是模型能在训练时看到动作片段内部的局部结构，例如接近物体、抓取、移动和释放之间的连续关系。

本实验直接调用 LeRobot 的 ACTPolicy，结构包括双视角图像编码、机器人状态编码、Transformer decoder 和 VAE 风格的训练目标。动作误差使用 Action L1，即预测动作和数据集中专家动作之间的平均绝对差。训练目标为 Action L1 与 KL 正则的加权和，其中动作分块长度为 16，kl_weight=10.0。在跨环境评估中，环境 D 的背景、物体布局和视觉风格相对训练环境发生变化，因此模型是否仍能输出接近专家的动作，是衡量泛化能力的关键。

3.4 训练配置


两个模型保持相同网络结构和核心超参数，只改变训练数据来源。训练过程使用 mixed precision 加速；loss、Action L1、学习率曲线和配置摘要均导出到 `hw3/task2/results/`，便于和最终图表对应。

表 7: Task 2 ACT 训练配置

项目	配置
模型	LeRobot ACTPolicy, 双视角图像 + 机器人状态输入
训练任务	<code>act_splitA: splitA</code> ; <code>act_splitABC: splitA+splitB+splitC</code>
评估任务	两个模型均在 <code>splitD</code> 上 zero-shot 离线评估
图像尺寸	96×96
动作维度 / 状态维度	action dim 7 / state dim 15
动作分块长度	<code>chunk_size=16</code>
Transformer 配置	hidden dim 256, heads 4, layers 3, dropout 0.1
训练目标	Action L1 + VAE KL 项, <code>kl_weight=10.0</code>
优化器参数	learning rate 1×10^{-4} , weight decay 1×10^{-4}
训练轮数与 batch size	8 epochs, train batch size 128, eval batch size 256
随机种子与加速	seed 42, AMP 开启, num workers 8
实验记录	GitHub <code>hw3/task2/results/curves/</code> 与 <code>results/figures/</code>
模型托管	youngchen/CS60003/hw3/task2/

3.5 训练曲线与收敛对比

图 3 展示了训练日志导出的训练和验证曲线。`act_splitABC` 的训练数据约为 `act_splitA` 的三倍，因此总训练 step 更多；两者都能稳定下降，说明相同 ACT 结构在单环境和多环境训练下都能有效拟合专家动作。从验证曲线看，多环境联合模型在 D 环境上的 Action L1 始终处于更低区间，说明加入 B/C 环境不是简单增加训练时长，而是让模型见到更多视觉背景和操作变化，从而减少对环境 A 外观的过拟合。



(a) 训练 loss 曲线



(b) 训练 Action L1 曲线



(c) 环境 D 验证 Action L1 曲线

图 3: Task 2 训练曲线。源数据位于 GitHub 的 [hw3/task2/results/curves/](https://github.com/hw3/task2/results/curves/)。

3.6 Zero-shot 评估结果

表 8 汇总了两个模型在环境 D 上的 Action L1。主结论使用 `final.pt`，因为它没有根据 D 环境误差挑选 checkpoint，更接近真正的 zero-shot 评估。`act_splitABC` 的 final Action L1 为 0.1549013643，低于 `act_splitA` 的 0.1886211640，绝对下降 0.0337197997，相对提升 17.88%。`best.pt` 结果也保持相同排序，但由于 `best checkpoint` 使用了 D 上离线误差做选择，因此只作为参考。

表 8: Task 2 环境 D zero-shot Action L1 结果

模型	训练数据	<code>final.pt</code> Action L1	<code>best.pt</code> Action L1	相对提升
<code>act_splitA</code>	<code>splitA</code>	0.1886211640	0.1731817282	-
<code>act_splitABC</code>	<code>splitA+splitB+splitC</code>	0.1549013643	0.1464656246	17.88%

3.7 配对统计与稳定性分析

仅看平均值可能掩盖局部失败，因此进一步按 `episode`、`task` 和动作维度做配对比较。表 9 显示，多环境模型不是只在少数样本上大幅改善，而是在大多数配对项上稳定更好：5124 个 `episode` 中有 4041 个更优，389 个任务索引中有 355 个更优，7 个动作维度全部更优。`bootstrap` 置信区间均为正，说明改进方向稳定。

这些统计让结论更稳。`A-only` 模型只见过一种背景和物体布局，更容易把特定视觉纹理和动作绑定在一起；`A/B/C` 联合模型见过同类任务在不同外观下的变化，更容易关注双视角图像里真正和操作有关的部分，例如机械臂、目标物体和接触状态。`ACT` 的动作分块也有帮助：模型预测的是一段动作，而不是单步反应，所以短时视觉偏移或局部遮挡不容易立刻把动作带偏。




图 4: 单环境训练与多环境联合训练在 splitD 上的 Action L1 对比。数值越低越好。

表 9: Task 2 final checkpoint 配对统计摘要

粒度	配对数	ABC 更优数	ABC 更优比例	平均 L1 提升	95% CI
Episode	5124	4041	78.86%	0.032959	[0.031753, 0.034230]
Task	389	355	91.26%	0.031384	[0.028808, 0.034193]
Action dim	7	7	100.00%	0.033752	[0.012247, 0.070059]

3.8 复现、托管与当前限制

复现检查脚本位于 `hw3/task2/scripts/`, 文件名为 `check_reproducibility.sh`。它会检查四个 split 的 episode/frame 数、结果文件完整性, 以及 `final.pt` 路径下 `act_splitABC` 是否优于 `act_splitA`。训练权重上传到 ModelScope 统一项目的 [youngchen/CS60003/hw3/task2/](#) 子目录, 包括两个模型的 `best.pt`、`final.pt`、`latest.pt`、配置、训练摘要和评估结果表。

需要说明的是, 本文没有报告官方 CALVIN simulator 的真实 Success Rate, 而是采用任务允许的动作误差作为 zero-shot 指标。原因是当前 LeRobot splitD 缺少官方 simulator 评估所需的原始 `validation/.hydra/merged_config.yaml`, 直接运行官方 Success Rate 脚本会缺少环境状态配置。相关探测只保留在交付目录的脚本和日志中; 就这份报告而言, Action L1 是更可复现、也更适合横向比较的主指标。

4 结论

Task 1 实现了完整的多源 3D 资产融合链路: 真实物体 A 使用 COLMAP + 3DGS, 虚拟物体 B 使用文本到 3D/SDS, 真实单图物体 C 使用 Zero123, 背景使用 Mip-NeRF 360 counter 的 3DGS。最终没有采用 2D 后合成, 而是把 A/background 的 splat 与 B/C 的 mesh surface splats 统一到同一个 gsplat renderer 中, 并通过前景聚焦相机生成 1080p 多视角视频。实验也显示三种资产路径各有取舍: 多视角重建真实性最好但依赖拍摄和 COLMAP; 文本生成自由度高但 prompt 一致性有限; 单图生成开销较低但背面/侧面更依赖先验。

Task 2 给出了 ACT 跨环境泛化实验: `act_splitA` 使用环境 A 训练, `act_splitABC` 使用环境 A/B/C 联合训练, 两个模型都在未见过的环境 D 上评估。按 `final.pt` 计算, 联合训练将 Action L1 从 0.1886211640 降至 0.1549013643, 相对提升 17.88%; episode、task 和动作维度的配对统计也一致支持该结论。整体来看, 多环境数据提升了 ACT 策略对视觉分布偏移的鲁棒性, 动作分块机制则帮助策略在短时视觉变化下保持更平滑、更稳定的动作输出。