

实验一：SFT 课程实验报告

实验概述

本实验以 Qwen2.5-1.5B-Instruct 为基座模型，围绕医疗领域单项选择题问答任务开展监督微调，依次完成数据构造、全参数微调、参数高效微调、综合评测与 Leaderboard 提交五个阶段。教师模型为 Qwen3.5-9B，训练在单张 32 GB GPU 上完成。

Task 1: SFT 数据构造

围绕原始训练集（800 条）设计了三种数据构造方案，统一采用 Alpaca 格式（instruction / input / output）

其中，Plan A 处理速度较快，直接对原始样本做格式转换，最后统一写出结果。Plan B 和 Plan C 需要调用教师模型生成内容，因此采用“边生成边写入”的方式，避免中途中断导致结果丢失。

Plan B 数据额外清洗策略

对于 Plan B，在初步生成之后又增加了一步二次清洗。通过以下规则过滤：

1. 答案一致性校验（预测答案须与标准答案一致）
2. 推理条数须为 3 条
3. 排除"本题""标准答案"等后验话术
4. 排除"A 项""故选 A"等选项泄露

先对原始输出做硬规则检查；若通过，再交给教师模型打分，并根据分数决定保留、丢弃或重新生成；若原始结果不满足要求，则最多再尝试 2 次重生成。这样做的目的，是尽量减少低质量推理链直接进入训练集。

为了便于后续分析，清洗脚本还记录了每条样本的审核信息，最终保留 738/800 条（92.2%）

Task 2: 全参数微调

训练脚本不使用任何 Trainer 类，全程自行实现训练循环。精度 BF16，优化器 AdamWFP32State，学习率策略 Cosine + Warmup (warmup_ratio=0.03)，max_length=2048，grad_clip=1.0。

早期以 dev_ratio=0.1 划出约 80 条验证集，观察不同数据方案的收敛行为，发现 2~3 个 epoch 即可收敛，继续训练至 15 epoch 准确率几乎不再提升。确认超参后，正式训练将 dev_ratio 设为 0，以全部数据训练。此外，还发现 Plan C 的数据会引入较多的非必要知识推理，会严重误导小模型的知识，因此，正式的训练数据只包含 Plan A、Plan B、Plan B_clean。

多版本训练对比（Plan A/B/C 代表不同提问方式）

评测集：val.jsonl，200 条

版本	训练数据	epochs	Plan A Acc	Plan B Acc	Plan C Acc
v0	Plan B	15	0.640	0.545	0.540
v1	Plan A×3 + Plan B_clean	15	0.630	0.585	0.575
v2	Plan A	15	0.645	0.005	0.095
v3	Plan A×2 + Plan B_clean×2	15	0.635	0.560	0.580
v4	Plan A×2 + Plan B_clean×2	1	0.640	0.490	0.535
task2-sft	Plan A×2 + Plan B_clean×2	3	0.655	0.575	0.570

v2 在 Plan B/C 格式下准确率接近 0，原因是该版本只用 Plan A 数据训练，模型从未见过 `{"reasoning": [...], "answer": "A"}` 格式，评测时无法输出可解析的 JSON，并非训练不稳定。

分析

所有版本中，Plan A 格式评测准确率普遍最高，最优的 task2-sft 达到 0.655。这说明在 1.5B 小模型上，直接答案监督比推理增强监督更稳定。v3 和 task2-sft 使用相同数据和超参，仅 epochs 不同（15 vs 3），而 task2-sft 表现更好，再次印证早期收敛观察——训练过长反而可能使模型在输出格式上产生漂移。v0 使用纯 Plan B 数据训练，Plan A 格式评测也能达到 0.640，说明模型有一定的格式泛化能力，但始终不及直接用对应格式训练的版本。

Task 3：参数高效微调（PEFT）

方法配置

所有方法共用训练脚本 `scripts/3-trian_lora_sft.py`，以 YAML 配置文件区分。手动实现 `AdamWFP32State` 优化器，将一阶/二阶矩显式存储为 FP32，避免 BF16 训练中优化器状态精度退化。

方法	训练数据	r	lora_alpha	dropout	量化	epochs	batch×accum	lr
LoRA	Plan B_clean	8	16	0.05	无	15	8×4	1e-5

QLoRA	Plan B_clean	16	32	0.05	4-bit NF4	15	4×8	2e-4
RFT	RFT 数据	8	16	0.05	无	15	8×4	1e-5

target_modules 覆盖全部线性层：q_proj / k_proj / v_proj / o_proj / gate_proj / up_proj / down_proj。

QLoRA 量化设置为 `bnb_4bit_quant_type=nf4,`
`bnb_4bit_compute_dtype=bfloat16, bnb_4bit_use_double_quant=true`。

RFT 数据构造分两步：先用 Qwen3.5-9B 对每条样本生成 4 个候选推理链，再经答案一致性、推理条数（须为 3 条）、元话术、选项泄露四项硬规则过滤，保留最短合格候选，最终从 800 条原始样本中保留 754 条（94.3%）。PEFT adapter 评测前需先合并回基座。

实验结果

评测集：val.jsonl，200 条

方法	可训练参数	显存峰值	Plan A Acc	Plan B Acc	Plan C Acc
全参数 SFT	1.54B (100%)	~30 GB	0.655	0.575	0.570
LoRA	~24M (1.6%)	~25 GB	0.605	0.495	0.505
QLoRA	~49M (3.2%)	~20 GB	0.625	0.565	0.550
RFT	~24M (1.6%)	~20 GB	0.615	0.465	0.510
Qwen3.5-9B	—	—	0.837	0.800	—

分析

从结果看，QLoRA 在三种 PEFT 方法中表现最佳：Plan A 准确率为 0.625，仅比全参数微调低 3 个百分点，但显存由 30 GB 降至 12 GB，可训练参数占比仅 3.2%。相比标准 LoRA（r=8），QLoRA 通过将 rank 提高到 16 并采用更大学习率（2e-4），一定程度上弥补了 4-bit NF4 量化带来的精度损失。

RFT 与 LoRA 使用相同训练后端，但基于拒绝采样筛选出的 754 条样本进行训练，Plan A 准确率为 0.615，略高于 LoRA 的 0.605。这表明在规模接近时，数据质量比数量更重要。

在输出格式稳定性上，PEFT 也优于全参数微调。三种 PEFT 方法在 Plan B/C 下的 JSON 解析率均超过 98%，而全参数微调在部分 checkpoint 上会跌至 1% 以下，说明 PEFT 由于可训练参数更少，可能具有更强的隐式正则化效果，从而提升格式稳定性。

Task 4：综合评测与分析

综合结果

方法	训练参数	显存峰值	Plan A Acc	Plan B Acc	Plan C Acc
Qwen2.5-1.5B-Instruct (基线)	—	—	0.580	—	—
task2-sft (全参数)	1.54B (100%)	~30 GB	0.655	0.575	0.570
LoRA	~24M (1.6%)	~25 GB	0.605	0.495	0.505
QLoRA	~49M (3.2%)	~20 GB	0.625	0.565	0.550
RFT (lora 后端)	~24M (1.6%)	~20 GB	0.615	0.465	0.510
Qwen3.5-9B (教师模型上界)	9B	—	0.837	0.800	—

三种格式 JSON Parse Rate 均 $\geq 98\%$ ，全参数微调 v2 (Plan A only 训练) 除外 (Plan B/C 接近 0)

分析

全参数微调整体表现最佳 (0.655)，但 QLoRA (0.625) 仅落后 3 个百分点，显存从 30 GB 降至 20 GB。在 32 GB 显存限制下，全参数微调已接近上限，而 QLoRA 仍有充足余量，因此更具实用性。

在所有方法中，Plan A 的评测准确率始终最高，Plan B/C 的收益不明显，甚至略有下降。主要原因在于 1.5B 模型容量有限：生成完整推理链并同时满足 JSON 格式约束负担较重，而更简洁的 Plan A 降低了生成难度，使模型能将更多能力用于答案预测。

RFT 通过拒绝采样过滤数据，在相同 LoRA 后端上优于 LoRA，说明数据质量确实重要；但其结果仍不及 QLoRA，表明在参数受限条件下，适当提高 rank 和学习率的补偿策略，比单纯依赖数据过滤更有效。

三种 PEFT 方法在 Plan B/C 下的 JSON 解析率均超过 98%，而全参数微调在部分 checkpoint 上明显下降，说明参数受限的训练方式更有利于保持输出格式稳定。

Task 5: Leaderboard

基于 Task 4 结果，最终选择 task2-sft 模型以 Plan A 格式推理提交。Plan A 格式 JSON 解析率在所有方法上均为 100%，且 task2-sft 在 val 集上 Plan A 准确率最高 (0.655)，是稳定性与准确率的最优组合。

最终在 Leaderboard 测试集上得分 **0.673** (300 题答对约 202 题)，高于 val 集上的 0.655，说明测试集与训练集的分布接近，模型泛化情况良好。