

实验三：RLHF 课程实验报告

实验概述

本实验以 Qwen3-0.6B 为基座模型，围绕 Countdown 数字游戏任务开展强化学习训练，依次完成 PPO 实现、DPO 偏好对齐、GRPO 在线强化学习、vLLM 推理加速与 Leaderboard 提交五个任务。教师模型为 Qwen3-8B，训练在单张 32 GB GPU 上完成。原始训练集 117 000 条（仅 numbers + target，无推理链），从训练集抽样 1 000 条用于在线 RL 之后的自蒸馏。

Task 0: PPO 损失函数实现

按题面公式 $L_{PPO} = -\mathbb{E}[\min(\rho A, \text{clip}(\rho, 1 - \epsilon, 1 + \epsilon)A)]$ 实现，其中 $\rho = \exp(\log \pi_{\text{new}} - \log \pi_{\text{old}})$ 。 `validate_ppo_implementation()` 输出：损失计算: True 梯度计算: True

loss 与梯度均与题面给定参考值在 `atol=1e-4` 内一致，验证通过。

Task 1: DPO 实验

数据构造方案

原始数据无推理链、无偏好标签。早期试探了 3 种方案（solver 表达式自配 / Qwen3-8B 完整生成 / 0.6B 多温度采样 + 教师评分），均因数据量小或开销大废弃。最终采用：

- **Plan D**（400 条，冷启动）：Qwen3-8B 教师生成 think+answer，失败时 solver 兜底；rejected 用 corrupt 规则化负例。
- **Full-AnswerOnly**（117k，主训）：solver 仅生成 `<answer>expr</answer>`，rejected 覆盖 7 类失败：`wrong_result`（×4 权）/ `number_usage_error` / `missing_answer` / `empty_answer` / `missing_muldiv` / `missing_paren` / `equation_answer`。

训练动态

DPO-1（200 步，~60 s）：reward margin 0 → 95，loss 衰减到 1.7e-3。DPO-2（3 000 步，~34 min）：reward margin 58 → 110.5，loss 3e-3 → 1.7e-5，已饱和。

训练设置与对比

评测：raw_test 500（candidate=64 BoN 投票）。

版本	数据	lr / bs / steps	Acc	平均 token

plan_d_formal_swan	Plan D 400	5e-6 / 1×8 / 200	0.250	8.0
full_answer_only_from_plan_d	Full-AnswerOnly 117k	2e-6 / 8×2 / 3000	0.260	7.9
full_answer_only_continue735	+ bs112 收尾	5e-7 / 112×1 / 735	0.324	6.5

三条结构性旁支（hardneg / multisolution / replay）以 bs=112 + 不同负例扩充再训 1k–1.8k 步，acc 均在 0.318–0.322，与主线 0.324 几乎相同。

分析

Full-AnswerOnly 阶段切到极短输出（~8 token），Format Rate 达 1.000；continue735 在 bs112 大批量低 lr 下进一步推到 **0.324**。结构旁支与主线几乎重合——DPO 偏好数据扩充已饱和，剩余瓶颈是模型推理能力本身，需切换到 GRPO 在线探索。

Task 2: RLVR 的 GRPO 实验

GRPO 实现

完全自实现（未用 trl）。核心：

- **Rollout**: local / vllm_api / vllm_exclusive 三后端，每 prompt 采 G 回答（T=0.6, top_p=0.95, enable_thinking=true）。
- **奖励**: $r = r_{\text{correct}} + 0.1 \cdot r_{\text{expr_valid}} + 0.05 \cdot r_{\text{format}} + 0.5 \cdot r_{\text{trunc}} + 0.3 \cdot r_{\text{brevity}}$ ，由 `<answer>` 标签解析 + AST 严格整除求值。
- **优势估计**: 组内 z-score 归一化。
- **策略更新**: PPO clip ($\epsilon=0.2$) + KL 正则（系数 0.05）。

多轮训练对比

Round	起点	G/bs	steps	step_time	single	BoN
r3	DPO-2 final	16/2	150	18.6 s	0.296 (ckpt-50)	0.668 (BoN16)
r7_vllm	r3/ckpt-50	32/4	500	154 s	0.368	0.756 (BoN32)

r3 在 step 50 reward 饱和（继续训练易 policy collapse），后续均以 r3/ckpt-50 为公共起点；r4–r6 三组关于 rollout 后端 / G / bs 的消融因显存或时间约束未持久化；最终选 r7_vllm（vllm_exclusive, G=32, bs=4）跑满 500 步。

r7_vllm 关键指标

24 h 16 min / 500 步；单步 rollout 130 s + update 24 s $\approx$ 154 s（rollout 84%）；显存峰值 19.6 GB；输出熵 0.520 $\rightarrow$ 0.584（未塌陷）；末段 reward_correct 0.0–0.5 震荡但 BoN32 稳定 0.756

分析

引入 truncation_penalty 和 brevity_bonus 后，平均输出 token 数控制在 130 左右（无 brevity 时 r3 的 BoN16 平均 226 token）；组内优势归一化使训练稳定性显著优于全局基线，未观察到 reward hacking。**single-pass 0.368 vs BoN32 0.756 之间的 39 个百分点 gap，正是后续 DPO 修正阶段试图弥合的目标：**让模型在不依赖外部投票的情况下，将"能答对"的能力固化为"单次就答对"。

Task 3: vLLM 加速

GRPO 的 rollout 占整步耗时约 84%，是首要瓶颈。最终采用 **vllm_exclusive** 模式（vLLM 独占进程提供 chat/completions 接口，训练进程通过 HTTP 调用），权重同步采用每 N 步显式 dump $\rightarrow$ vLLM 重载（`vllm_sync_interval`），实测 N=50 时同步开销 < 1%。

在 G=32 / bs=4 / max_response_length=1024 / thinking-mode 设定下，r7_vllm 单步耗时 **rollout 130 s + update 24 s $\approx$ 154 s**，显存峰值 19.6 GB；同超参的 local 后端（HF generate 同进程）对照实验单步 $\sim$ 178 s，**vllm_exclusive 提速约 1.18 $\times$** ，奖励曲线与 local 无显著差异。提速幅度有限的原因：max_response_length=1024 + thinking-mode 下 prefill 占比已较高，vLLM 主要优化的 KV cache 复用收益相对降低。

Task 4: Leaderboard 最终方案

流水线

最终采用 **DPO 冷启动 $\rightarrow$ DPO 主训 $\rightarrow$ 多轮 GRPO 强化 $\rightarrow$ DPO 失败题修正** 五阶段流水线：

1. DPO-1 (plan_d 400) $\rightarrow$ DPO-2 (Full-AnswerOnly 117k) $\rightarrow$ continue735 收尾
2. GRPO r3 $\rightarrow$ r3/ckpt-50 $\rightarrow$ r7_vllm (thinking-mode, KL=0.05, 500 步)
3. **DPO-3 r7_clean_sft_pass32_onepos_ep2**：在 v7_llm 后模型上重跑 pass@32，每题 1 个最佳正例 vs 最强负例配对，lr 1e-6 / 1 200 步
4. **DPO-4 r7_clean_onepos_targeted_failures_ep2**：在 DPO-3 后模型上跑 single-pass，失败题以 solver 表达式为 chosen、模型输出为 rejected（missing_answer 失败重复采样），lr 5e-7 / 260 步
5. **最终提交：pass@32 BoN cleaned**：DPO-4 模型在 raw_test 500 上跑 pass@32（T=0.6, top_p=0.95），每题挑最短的正确候选，经 `clean_prediction_for_submit` 处理后写入提交文件。

最终结果与分析

阶段	Acc (single)	Format	平均 token

DPO-2 final	0.260	1.000	7.9
DPO-2 continue735	0.324	1.000	6.5
GRPO r3/ckpt-50	0.296	0.414	138
GRPO r7_vllm/final	0.368	0.390	132
DPO-3 sft_pass32_onepos	0.432	0.488	133
DPO-4 onepos_targeted	0.472	0.504	150
DPO-4 + pass@32 BoN cleaned (提交)	0.796	0.800	185

BoN 上限演进：DPO-2 cand=512 0.356 → r3 BoN16 0.668 → r7_vllm BoN32 0.756 → **DPO-4 BoN32 0.796**。GRPO 打开探索空间（+40 pp），DPO-3/4 收窄分布（+4 pp）；single vs BoN 仍有 32.4 pp gap，提交版用 BoN32 兜底。

- **DPO 阶段：**极短输出（~8 token）拉满 Format=1.000，但牺牲推理空间，single 上限 0.324。结构性旁支几乎重合，偏好数据扩充已饱和。
- **GRPO 阶段：**thinking-mode 放开 think 段（~130 token），自由推理探索 multi-step 解。r7_vllm single 0.368、BoN32 0.756（+41.6 pp）——探索能力被显著放大，但单次采样稳定性未跟上。
- **DPO-3/4 修正：**用模型自身正例 + 失败题做反馈，single 0.368 → 0.472，且 BoN32 0.756 → 0.796——既推高 single 也抬高 BoN 上限。
- **典型案例：** [79, 17, 60] → 36 模型经 think 试 79×60 否决后命中 79-60+17；
[11, 34, 82, 80] → 56 需 34-(11×(80-82)) 含负数中间结果，single 不稳定但 BoN32 能命中。

关键思考与不足

1. **奖励设计的边际：**correctness reward 已驱动收敛，truncation/brevity 主要影响输出长度而非 single-pass 上限。0.6B 规模下瓶颈是推理能力本身。
2. **DPO vs GRPO：**DPO 单步 ~0.7 s，GRPO 单步 154 s（**220×**）。DPO 仅学到已有解法偏好，single 上限 0.324；GRPO 通过在线探索把 BoN32 推到 0.756。两者互补，先 DPO 后 GRPO。
3. **single vs BoN gap：**r7 39 pp、DPO-4 32.4 pp，DPO 修正难根除。提交版直接用 BoN32 兜底，32× 推理成本换稳态准确率。
4. **vLLM 加速：**rollout 占比越高收益越大；thinking-mode + max_len=1024 下 prefill 占比已高，vllm_exclusive 仅提速 1.18×