

实验五：智能体个体模拟课程实验报告

实验概述

本实验以 `Qwen2.5-1.5B-Instruct` 为基座模型，完成 Memory 检索、角色 Agent、角色 SFT/GRPO、训练模型与 Memory 结合、通用指令训练及最终提交。记忆检索使用 `Qwen3-Embedding-0.6B`；角色评估由 `Qwen3.5-35B-A3B` 作为 LLM-as-a-Judge，从 memorisation、values、personality、hallucination、answer_quality 与 overall 等维度评分。

Leaderboard 项目	最终结果
角色模拟（完成 500/500，70% 权重）	68.90 / 100
通用指令（30% 权重）	64.55 / 100
最终加权分数	67.60 / 100

最终分数按 $0.7 \times 68.90 + 0.3 \times 64.55 = 67.60$ 计算。核心目标是在角色一致性与严格指令遵循之间取得平衡。

Task 0-1: Memory 检索与角色 Agent

Memory Pool 由 scene 与 dialogue 构成：前者保留地点、背景和 Persona 摘要，后者保留情绪、主题、角色发言及上下文。综合检索分数为 $0.65 \cdot semantic + 0.25 \cdot lexical + 0.10 \cdot importance$ 。推理时检索 top-5，并在 prompt 中要求模型只使用相关记忆、不泄露检索过程、不编造冲突事实。三路打分各司其职：semantic 负责语义召回，lexical 帮助召回含专有名词的记忆，importance 在语义相近时偏向更关键的事实，从而保证召回内容对访谈回答有价值。

配置	Judge winner	平均时延
Question-only	3	1.02 s/条
Persona + Question	203	1.49 s/条
Persona + Retrieved Memories + Question	284	5.57 s/条
Tie	10	—

Persona + Memory 在 500 条全量评测中最常胜出，说明外部记忆能补充模型未稳定记住的经历、关系和偏好。主系统 P50/P95 时延为 5.71/6.86 s，吞吐 4.66 条/s；其中检索仅约 0.045 s，主要开销来自生成。

Task 2：合成访谈数据与 SFT + GRPO

原始 dialogue 训练学习的是多轮对话续写，与最终“采访问题 → 第一人称角色回答”的评测形式存在分布偏移。因此我们依据 `characters/wiki_*.txt`、scene 与 dialogue 文件中的角色证据，调用 `Qwen3.5-35B-A3B` 为每个角色生成最多 16 条采访式 QA。评测问题不进入生成 prompt；合成后删除空值和非法格式，并对 held-out 问题做全局 exact 与同角色 fuzzy 过滤。最终保留 1002 条，训练 952 条、验证 50 条。

候选方案	胜/负/平	overall 候选/基线	结论
原始 dialogue SFT	115/383/2	2.354 / 3.256	分布不匹配
原始 dialogue GRPO	120/378/2	2.331 / 3.256	奖励难弥补偏差
合成访谈 SFT	372/126/2	3.742 / 2.800	形式对齐后提升
合成访谈 GRPO r2	407/92/1	3.892 / 2.800	最优角色一致性

SFT 与 GRPO 使用相同的 952/50 训练验证划分，但优化信号不同：SFT 输入 Persona 与采访问题，监督输出第一人称回答，用于学习背景、语气、价值观和经历；GRPO 在该 checkpoint 上生成多个候选，由 `Qwen3.5-35B-A3B` 按上述维度评分。reward 按 overall、memorisation、hallucination、values、personality、answer_quality 加权，并对空回答、AI 声明、英文问题中混入 CJK 文本和过长回答设置得分上限，最后映射为训练 reward。结果说明数据形式对齐比单纯增加训练轮次更关键，GRPO 则在此基础上继续改善角色一致性。Judge prompt 见 `lab5/task_scripts/utils.py`，reward prompt 见 `lab5/task_scripts/task2_grpo_reward.py`。

Task 3：训练模型与 Memory 结合

Trained 表示 Task 2 经过 SFT + GRPO 的角色模型。本任务只比较加入 Memory 前后的主结果，胜/负/平均由同一个 LLM-as-a-Judge 逐题成对评估。

对比	胜/负/平	结论
Base + Persona + Memory vs Base + Persona	284/203/3	

		Memory 对基础模型更常胜出，能改善角色回答
Trained + Persona + Memory vs Trained + Persona	280/215/5	角色训练后，外部 Memory 仍能继续提供帮助

结果进一步回答了四个问题：

- **是否优于单独训练模型：**是，Trained + Persona + Memory 以 280/215/5 胜出，overall 由 3.582 升至 3.722。
- **是否能补充未记住的事实：**能，memorisation 由 2.910 升至 3.262，主要改善经历、关系、地点与事件细节。
- **是否破坏已有风格：**整体没有，personality 由 3.510 升至 3.640，相关 Memory 能与已学习的角色语气兼容。
- **主要风险：**hallucination 由 3.836 降至 3.572，明弱相关记忆可能诱发过度外推，需要约束模型只使用相关证据。

因此，训练主要补充语气和价值观，Memory 主要补充事实和经历，两者结合效果更好；继续优化的重点不是机械增加 Memory，而是提升检索相关性和模型的选择性使用能力。

Task 4：通用指令能力与最终提交

角色微调使 dev strict 指令准确率由基座模型的 0.58 降至 0.26，证明角色适配与通用指令遵循存在明显 trade-off。最终提交不再使用角色数据进行参数训练，而是从基座模型执行四阶段通用指令训练，并在角色推理时叠加 Task 1 Memory 检索。四个阶段均在全参数训练下完成，关键超参为：阶段 1 学习率 1e-5、约 180 iters；阶段 2/4 规则 GRPO 学习率 1e-6 到 2e-6、每个 prompt 采样 4 个候选；阶段 4 将上下文长度扩到 6144。

阶段	方法	数据	规模 train/val
1	通用 SFT	Tulu-3 personas instruction following	16000 / 350
2	规则 GRPO	RLVR-IFeval + ifeval_rule	12000 / 500
3	Teacher SFT	Qwen3.5-35B-A3B 生成并经规则筛选	963 / 107
4	二次规则 GRPO	复用 RLVR-IFeval	12000 / 500

Teacher 阶段共生成 1400 条候选，规则检查接受 1070 条、丢弃 330 条。所有通用训练数据均来自外部公开数据或 Teacher 蒸馏，与 Lab5 instruction dev/test 的 exact prompt 重叠为 0；不使用 test 答

案。最终路线把“角色模拟”转化为“强指令模型服从角色设定，并利用可见 Memory 回答”，从而避免角色微调造成的指令能力塌缩。

三类训练样本的格式如下。

数据类型	样本结构	训练信号
Tulu 通用 SFT	<code>user instruction → assistant answer</code> ，以标准 messages 保存	对完整答案做监督学习，建立基础指令遵循
RLVR-IFeval GRPO	单轮 user prompt + constraint_type / constraint 等规则元数据	无固定参考答案，由规则函数检查格式、关键词、大小写、长度和标点并返回 reward
Teacher SFT	RLVR-IFeval prompt + Qwen3.5-35B-A3B 候选答案	仅保留通过公开规则检查的候选，作为高质量监督标签

阶段 2 与阶段 4 复用同一 RLVR-IFeval 数据文件，但实际训练由 `train_iters` 控制，并不等价于完整遍历两次。当前最佳统一模型的训练集不依赖角色数据记忆具体人物事实。

值得注意的是，最终模型没有使用 Lab5 角色数据进行参数更新；阶段 1 验证集中的 50 条 role memory replay 仅用于验证，不参与梯度更新。该模型在角色模拟上仍取得 68.90 的 Leaderboard 分数。这说明在强指令基座之上，“扮演某角色”被有效转化为“服从‘以该角色身份、依据给定 Persona 与检索记忆作答’这条指令”：具体角色知识主要来自推理时注入的上下文，而不是通过角色训练写入参数。这也是我们选择从基座而非角色模型出发做指令训练的原因——避免先用角色数据过拟合、再艰难恢复指令能力，转而用与模型解耦的 Memory 检索补足角色事实。

实验问题回答与不足

1. **角色适配与通用指令跟随是否存在 trade-off?** 存在。角色微调使指令准确率从 0.58 降至 0.26。
2. **哪种方案最均衡?** 四阶段通用指令训练 + Task 1 Memory 检索最均衡，正式 Leaderboard 为角色 68.90、指令 64.55、加权 67.60。
3. **继续改进时优先优化什么?** 优先优化检索器重排、去噪与训练数据质量，其次调整 Prompt，最后再考虑替换训练算法。

局限与下一步：

- **检索器**：加入 cross-encoder 重排、动态 top-k 与同源去重，减少进入上下文的弱相关记忆。
- **Prompt**：强化“证据不足不扩写、冲突时以显式 Persona 为准”，并压缩冗余上下文。
- **训练数据**：补充含干扰/冲突 Memory 与严格格式的困难样本，让模型学会选择性引用。
- **训练目标**：角色侧拆分事实忠实与风格奖励；指令侧覆盖分隔符、词频、大小写等薄弱约束。