

复合优化算法求解 LASSO 回归

综合实验报告

最优化 · 期末实验

选题章节：第八章复合优化算法

小组成员：檀宗晗、杨晨、朱建军、侯明扬、李佳航、马辰昊

实验方法：近似点梯度法 (ISTA)、Nesterov 加速梯度法 (FISTA)、坐标下降法 (Coordinate Descent)

目录

1	实验总目标	3
2	问题描述	3
2.1	LASSO 回归	3
2.2	复合结构分解	3
2.3	为什么选这个问题	4
3	算法原理	4
3.1	近似点梯度法 (ISTA)	4
3.2	Nesterov 加速梯度法 (FISTA)	4
3.3	坐标下降法 (Coordinate Descent)	5
4	实验一：近似点梯度法 (ISTA)	6
4.1	实验设置	6
4.2	实验结果	6
4.3	结果分析	6
4.4	实验图表	7

5	实验二：Nesterov 加速梯度法 (FISTA)	8
5.1	实验设置	8
5.2	实验结果	9
5.3	结果分析	9
5.4	实验图表	9
6	实验三：坐标下降法 (Coordinate Descent)	11
6.1	实验设置	11
6.2	实验结果	12
6.3	Active Set 加速效果	12
6.4	结果分析	12
6.5	实验图表	13
7	三种算法综合对比	15
7.1	理论性质对比	15
7.2	实验性能对比	15
7.3	关键发现	16
7.3.1	发现一：FISTA 是“免费午餐”	16
7.3.2	发现二：坐标下降在 LASSO 问题上收敛最快	16
7.3.3	发现三：ISTA 在有限迭代内不可靠	17
7.3.4	发现四：数据集规模影响收敛行为	17
7.4	使用场景推荐	17
8	结论	17

1 实验总目标

本系列实验围绕 LASSO 稀疏回归问题，分别使用三种复合优化算法进行求解，量化比较它们在**收敛速度**、**计算代价**和**稀疏性恢复**上的差异：

表 1: 三种算法概览

算法	核心思想	理论收敛率
Proximal Gradient (ISTA)	复合结构分解的直接实现	$O(1/k)$
NAG / FISTA	在 ISTA 基础上引入动量外推	$O(1/k^2)$
Coordinate Descent	逐坐标精确求解子问题	无统一保证，实践极快

三种算法代表了处理复合优化问题的三条路线：“基础方案”、“加速方案”和“走不同路线的方案”，通过公平比较可以深入理解每种方法的优势与局限。

2 问题描述

2.1 LASSO 回归

Lasso (Least Absolute Shrinkage and Selection Operator) 在最小二乘损失上叠加 L1 正则项：

$$\min_x \frac{1}{2n} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

其中：

- $A \in \mathbb{R}^{n \times p}$: 设计矩阵（特征矩阵）
- $b \in \mathbb{R}^n$: 观测向量（标签）
- $x \in \mathbb{R}^p$: 待求系数向量
- $\lambda > 0$: 正则化参数，控制稀疏度

2.2 复合结构分解

目标函数天然拆分为光滑部分 + 不光滑部分：

$$\min_x f(x) + g(x)$$

$$f(x) = \frac{1}{2n} \|Ax - b\|_2^2 \quad \leftarrow \text{光滑凸, 梯度} = A^\top(Ax - b)/n$$

$$g(x) = \lambda \|x\|_1 \quad \leftarrow \text{不光滑凸, 有近似点算子}$$

L1 正则项的**近似点算子**（软阈值函数）有解析解：

$$\text{prox}_\lambda(v)_j = \text{sign}(v_j) \cdot \max(|v_j| - \lambda, 0)$$

这是整个求解框架的核心工具——把不可微的 L1 项“吸收”进一个可直接执行的算子里。

2.3 为什么选这个问题

1. 目标函数是复合优化的标准形式，结构典型
2. L1 近似点算子有解析解，便于实现和分析
3. 三种算法各有侧重，可以公平比较“每步代价相同时的差异”
4. 在高维数据 ($p \gg n$) 场景下能自动选择特征、产生稀疏解，实际意义强

3 算法原理

3.1 近似点梯度法 (ISTA)

Lasso 不能直接用梯度下降 (L1 在零点不可微)，但复合结构允许拆开处理。每次迭代包含两步：

第一步，梯度步 (对光滑项)：

$$u_k = x_k - \frac{1}{L} \nabla f(x_k)$$

第二步，近似点步 (对不光滑项，即软阈值)：

$$x_{k+1} = \text{prox}_{\lambda/L}(u_k) = S_{\lambda/L} \left(x_k - \frac{1}{L} A^\top (Ax_k - b)/n \right)$$

其中步长 $1/L$ ， $L = \|A\|_2^2/n$ 为梯度 Lipschitz 常数，保证每步目标函数不上升。

理论收敛率： $f(x_k) - f^* = O(1/k)$

特点： 实现最简，结构清晰，是复合优化方法的基础方案。

3.2 Nesterov 加速梯度法 (FISTA)

核心改动： 不在 x_k 处算梯度，而在一个**外推点** y_k 处算。完整迭代格式 (4 步)：

Algorithm 1 FISTA (Nesterov 加速梯度法)

- 1: **Step 1** 梯度步 (在外推点 y_k 处)： $v_k = y_k - \frac{1}{L} \nabla f(y_k)$
 - 2: **Step 2** 近似点步 (软阈值)： $x_k = \text{prox}_{\lambda/L}(v_k)$
 - 3: **Step 3** 动量参数更新： $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$
 - 4: **Step 4** 外推点更新 (动量项)： $y_{k+1} = x_k + \frac{t_k - 1}{t_{k+1}}(x_k - x_{k-1})$
-

与 ISTA 相比，**唯一区别**是把梯度计算点从 x_k 换成了 y_k 。

外推系数 $(t_k - 1)/t_{k+1}$ 随 k 增大趋近于 1，当 k 较大时外推点几乎沿上一步方向再“冲”一段，类似物理惯性。ISTA 每步只用当前梯度，NAG 通过外推利用历史方向信息。

理论收敛率：

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k+1)^2} = O(1/k^2)$$

关键点：收敛率从 $O(1/k)$ 提升到 $O(1/k^2)$ ，**每步计算代价与 ISTA 完全相同。**

3.3 坐标下降法 (Coordinate Descent)

不整体更新 x ，每次固定其他坐标，只对第 j 个坐标精确求解子问题：

$$\min_{x_j} \frac{1}{2n} \|A_{\cdot j} x_j - r_{-j}\|_2^2 + \lambda |x_j|$$

该子问题有**闭式解**：

$$x_j^* = \frac{S_\lambda(A_{\cdot j}^\top r_{-j}/n)}{\|A_{\cdot j}\|_2^2/n}$$

其中 $r_{-j} = b - \sum_{k \neq j} A_{\cdot k} x_k$ 是偏残差。

高效实现：维护残差向量 $r = b - Ax$ ，每步更新仅需 $O(n)$ 操作：

1. 计算 $\rho_j = A_{\cdot j}^\top r/n + x_j \cdot \|A_{\cdot j}\|^2/n$
2. 更新 $x_j^{\text{new}} = S_\lambda(\rho_j) / (\|A_{\cdot j}\|^2/n)$
3. 增量更新残差 $r \leftarrow r + A_{\cdot j} \cdot (x_j - x_j^{\text{new}})$

Active Set 加速策略：对于高维稀疏问题，绝大多数坐标始终为零。Active Set 策略仅更新当前非零坐标或违反 KKT 条件的坐标，大幅减少无效计算。

特点：每步精确求解（相当于精确线搜索），不需要调步长，在 LASSO 问题上实践收敛极快。

4 实验一：近似点梯度法 (ISTA)

4.1 实验设置

表 2: 实验一参数设置

参数	值
训练样本数	240
测试样本数	120
特征数	60
真实非零特征数	8
正则化参数 λ	$0.327529 \ (0.12 \times \lambda_{\max})$
步长	$1/L = 0.4771 \ (L = \ X\ _2^2/n)$

本实验使用**较小规模**的数据集，重点展示 Proximal Gradient 的基本工作流程和稀疏系数恢复效果。

4.2 实验结果

表 3: 实验一结果

算法	λ	步长	迭代次数	最终目标值	测试 MSE	F1	非零系数	时间 (s)
ISTA	0.3275	0.4771	39	4.2856	1.2931	1.000	8	0.00126

4.3 结果分析

- **完美特征选择**：恢复出 8 个非零系数，与真实非零系数个数一致， $F1 = 1.0$ 。
- **快速收敛**：仅需 39 次迭代即达收敛（小规模问题），目标函数差距持续下降。
- **稀疏化效果**：soft-thresholding 把小系数压为零，保留重要特征，体现 L1 正则的变量选择作用。

4.4 实验图表




图 1: ISTA 收敛曲线——目标函数差距随迭代持续下降，算法稳定收敛




图 2: ISTA 目标函数值变化——前几次迭代下降最快，随后趋稳




图 3: ISTA 稀疏系数恢复——大部分无关特征被压为零，8 个重要特征被正确保留

5 实验二：Nesterov 加速梯度法 (FISTA)

5.1 实验设置

表 4: 实验二参数设置

参数	值
样本数 n	200
特征数 p	500
特征生成方式	潜因子模型（15 个公共因子生成 500 个高度相关特征）
真实非零系数	12
正则化参数 λ	0.04
最大迭代	400
基准解 f^*	sklearn 迭代 10 万次到机器精度

本实验刻意构造**高条件数**、**特征高度相关**的数据集，让三种算法的差异充分展开。同时实现了 ISTA、FISTA 和坐标下降三种方法，在同一数据上做横向对比。

5.2 实验结果

表 5: 实验二结果

算法	迭代次数	最终次优性间隔	非零系数个数
ISTA	400	4.52×10^{-3}	40 (未收敛)
FISTA	400	1.37×10^{-6}	15 (正确)
坐标下降	400	3.30×10^{-12}	15 (正确)

5.3 结果分析

- **FISTA vs ISTA**: 同样 400 步、同样每步计算量, FISTA 比 ISTA 精确约 **3300** 倍。
- **动量外推的物理直觉**: 外推系数 $(t_k - 1)/t_{k+1}$ 随迭代增大趋近 1, 大 k 时外推点 $\approx$ 当前点 + 上一步方向, 类似“惯性”。
- **稀疏性恢复**: ISTA 跑满 400 步仍未收敛 (40 个非零系数), FISTA 和坐标下降正确恢复 15 个非零系数。
- **理论验证**: 在 log 尺度收敛图上, ISTA 曲线斜率 ≈ -1 、FISTA 斜率 ≈ -2 , 与 $O(1/k)$ 和 $O(1/k^2)$ 理论预测吻合。

5.4 实验图表




图 4: 三种算法收敛曲线——双子图: 左图线性尺度目标函数值, 右图对数尺度次优性间隔, 附 $O(1/k)$ 和 $O(1/k^2)$ 参考线




图 5: NAG 动量加速效果（核心图）——ISTA（蓝色虚线）vs FISTA（红色实线），约第 30 步后动量显著拉开差距




图 6: 系数恢复结果——三列子图：ISTA 非零系数散布（40 个），FISTA 和坐标下降精确定位在真实稀疏位置（15 个）




图 7: 正则化参数 λ 的影响——左图：非零系数数量随 λ 变化， $\lambda = 0.04$ 处有拐点；右图：目标函数值随 λ 增大而升高




图 8: 三种算法综合对比柱状图——(a) 迭代次数, (b) 实际耗时, (c) 最终次优性间隔 (对数尺度)

6 实验三：坐标下降法 (Coordinate Descent)

6.1 实验设置

表 6: 实验三参数设置

参数	值
样本数 n	200
特征数 p	500
特征相关性	AR(1), $\rho = 0.7$
真实非零系数	15
正则化参数 λ	0.441383 ($0.1 \times \lambda_{\max}$)
噪声标准差	0.5
最大迭代	400 (所有算法统一)
收敛阈值	10^{-10}

本实验以坐标下降为主算法, ISTA 和 FISTA 为对照基线, 重点展示 Active Set 加速策略的效果。

6.2 实验结果

表 7: 实验三结果

算法	迭代/轮数	时间 (s)	最终目标值	与 f^* 差距	非零系数
ISTA	400	0.0732	17.46112	1.40×10^{-5}	20
FISTA	400	0.0635	17.46110	3.19×10^{-8}	20
坐标下降 (Active Set)	55	0.0387	17.46110	$0.00 \times 10^{+0}$	20
坐标下降 (全量)	55	0.2399	17.46110	3.55×10^{-15}	20

参考最优值 $f^* = 17.46110226$

6.3 Active Set 加速效果

表 8: Active Set vs. 全量遍历对比 ($p = 500$, 55 轮收敛)

指标	Active Set	全量遍历	比值
坐标访问次数	2,036	27,500	13.5× 减少
值变化次数	1,663	1,710	$\sim 1.0\times$
实际耗时	0.056s	0.335s	6.0× 加速

- Active Set 避免了 **25,464** 次冗余坐标遍历
- 两种策略的“值变化次数”几乎相同 ($\sim 1,700$)，说明 Active Set 精准识别了需要更新的坐标，**不损失精度**
- 时间加速比 ($6.0\times$) 低于访问比 ($13.5\times$)，因 Active Set 每轮需额外计算梯度做 KKT 检查
- 两种策略得到**完全相同的解** ($\|x_A - x_B\|_\infty = 1.12 \times 10^{-11}$)

6.4 结果分析

- **坐标下降法在 LASSO 问题上收敛极快**：仅需 **55 轮**即收敛到机器精度 ($f - f^* < 10^{-15}$)，远少于 ISTA/FISTA 的 400 次迭代。
- **根本原因**：坐标下降利用了 LASSO 问题的坐标可分结构——每个坐标子问题有精确闭式解，相当于每步做“精确线搜索”。

- **系数恢复质量**：三种方法均能正确识别大部分非零特征，坐标下降和 FISTA 恢复的系数值更接近真实值。
- **正则化路径**：LASSO 的系数随 λ 连续收缩到**恰好为零**（不同于岭回归只是接近零），体现了软阈值的特性。

6.5 实验图表




图 9: 收敛曲线对比——坐标下降 55 轮收敛 vs ISTA/FISTA 400 次仍未收敛




图 10: Active Set 加速效果——坐标访问 2,036 vs 27,500 ($13.5\times$), 时间 0.056s vs 0.335s ($6.0\times$)




图 11: 系数恢复对比——三种方法均正确识别稀疏模式, CD 和 FISTA 的系数更接近真实值




图 12: 正则化路径——四面板: 系数路径、稀疏度 vs λ 、目标函数 vs λ 、Top-10 系数




图 13: 时间-精度权衡——不同算法在运行时间与最终精度之间的 trade-off

7 三种算法综合对比

7.1 理论性质对比

表 9: 三种算法理论性质对比

特性	ISTA	FISTA	Coordinate Descent
每步更新单位	全部坐标	全部坐标	1 个坐标
单步计算量	$O(np)$	$O(np)$	$O(n)$
每轮计算量	$O(np)$	$O(np)$	$O(np)$ (一轮 = p 次坐标更新)
步长选择	固定 $1/L$	固定 $1/L$	自动 (精确最小化)
理论收敛率	$O(1/k)$	$O(1/k^2)$	无统一保证
核心创新点	近似点框架	动量外推	坐标可分 + 闭式解

7.2 实验性能对比

基于实验二的高维高相关数据集 ($n = 200, p = 500$):

表 10: 实验性能对比（高维高相关数据集）

指标	ISTA	FISTA	Coordinate Descent
迭代次数	400	400	400
运行时间	~13ms	~13ms	~917ms
最终次优性间隔	4.52×10^{-3}	1.37×10^{-6}	3.30×10^{-12}
精度相对 ISTA	$1\times$	$\sim 3300\times$	$\sim 1.4 \times 10^9\times$
非零系数个数	40（错误）	15（正确）	15（正确）

基于实验三的 AR(1) 数据集 ($n = 200, p = 500, \rho = 0.7$):

表 11: 实验性能对比（AR(1) 数据集）

指标	ISTA	FISTA	CD (Active Set)	CD (全量)
迭代/轮数	400	400	55	55
运行时间 (s)	0.0732	0.0635	0.0387	0.2399
与 f^* 差距	1.40×10^{-5}	3.19×10^{-8}	$0.00 \times 10^{+0}$	3.55×10^{-15}
非零系数	20	20	20	20

7.3 关键发现

7.3.1 发现一：FISTA 是“免费午餐”

FISTA 相对 ISTA 的改动极小——只把梯度计算点从当前迭代点挪到外推点，增加的计算量可以忽略不计。但这一微小改动使理论收敛率从 $O(1/k)$ 提升到 $O(1/k^2)$ ，在实验中精度提升约 **3300 倍**。

一句话总结：NAG 是这次比较里的“免费午餐”——相对 ISTA 不增加任何每步代价，只靠一行外推公式就把收敛阶次提高了一档。

7.3.2 发现二：坐标下降在 LASSO 问题上收敛最快

坐标下降仅需 **55 轮**即达机器精度，远快于 ISTA/FISTA 的数百次迭代。根本原因是 LASSO 问题的**坐标可分结构**——每个一维子问题有精确闭式解，相当于在每条坐标方向上做精确线搜索。

但每个 epoch 需逐一更新全部 p 个坐标 ($p = 500$)，所以**总运行时间**反而比梯度方法长约 70 倍。配合 Active Set 策略后，计算量大幅降低 ($6\times$ 加速)，是实际应用中的首选。

7.3.3 发现三：ISTA 在有限迭代内不可靠

ISTA 在 400 步后仍未收敛，非零系数散布 (40 个而非真实 15 个)，可能对部分系数“收缩过度”。FISTA 和坐标下降则能正确恢复稀疏结构。这说明在实际应用中， $O(1/k)$ 的收敛率通常不够，加速或换用其他算法是必要的。

7.3.4 发现四：数据集规模影响收敛行为

实验一 ($p = 60$) 中 ISTA 仅需 39 次迭代即达完美特征选择，而实验二/三 ($p = 500$) 中 400 步仍未收敛。这表明：

- **小规模问题**：三种方法差异不大，ISTA 足够
- **大规模高维问题**：算法选择至关重要，ISTA 不可靠

7.4 使用场景推荐

表 12: 使用场景推荐

场景	推荐算法	原因
迭代预算有限、精度要求高	FISTA	$O(1/k^2)$ 收敛，每步代价与 ISTA 相同
需要极高精度、不在乎时间	坐标下降	闭式解精度极高，可达机器精度
实现简单、调参稳定	ISTA	最简实现，适合快速原型
特征近似正交	坐标下降	坐标间耦合弱，收敛最快
特征高度相关	FISTA	动量部分克服病态条件数的影响
高维稀疏 ($p \gg n$)	CD + Active Set	跳过零坐标，大幅减少计算量

8 结论

本系列实验通过三种不同的复合优化算法求解 LASSO 回归问题，系统地揭示了以下规律：

1. **复合优化框架的统一性**：三种算法都基于“光滑项用梯度处理，非光滑项用近似点算子处理”的复合优化思想，软阈值函数是共同的基础工具。
2. **加速策略的高效性**：FISTA 通过引入动量外推，在不增加每步计算代价的前提下，将理论收敛率从 $O(1/k)$ 提升到 $O(1/k^2)$ ，是实际应用中的默认选择。
3. **问题结构的重要性**：坐标下降法利用了 LASSO 的坐标可分结构，每个子问题有闭式解，在迭代轮数上远快于梯度类方法。配合 Active Set 策略可进一步大幅降低计算量。

4. **没有万能算法**: 每种算法都有其适用场景。ISTA 适合简单问题和学习理解; FISTA 适合需要快速收敛的通用场景; 坐标下降特别适合 LASSO 等坐标可分问题。选择算法时需结合问题结构和实际需求。
5. **实践启示**: 在工业界, 坐标下降法是 glmnet、scikit-learn 等主流机器学习库求解 LASSO 的默认方法, 正是因为它完美契合了 LASSO 问题的结构特点。而 FISTA 作为通用一阶加速方法, 适用于更广泛的复合优化问题。